



MSI

C5. Uczenie się przez obserwację (indukcja)

Włodzimierz Kasprzak

Zadanie 1. Klasteryzacja cech

Dany jest zbiór 15 próbek uczących 4 klas o postaci 3-wymiarowych wektorów cech. Załóżmy, że ich przynależność do klasy nie jest znana. Zastosować algorytm kwantyzacji z ustalaniem liczby klastrów – wykonać 2 iteracje tego algorytmu. Kwantyzacja korzysta z klasteryzacji k-średnich.

Oszacować wyniki wykonania 2 iteracji algorytmu kwantyzacji.

(Z uwagi na całkowite wartości cech mogą wystąpić zerowe wariancje – wtedy przyjąć wartość wariancji za równą 0.25).

Porównać przynależność próbek do klastrów z ich rzeczywistą klasą, podaną w ostatniej kolumnie tabelki.

<i>Indeks</i>	0	1	2	<i>Klasa</i>
1	16	27	10	1
2	16	27	12	1
3	18	29	8	1
4	17	28	8	1
5	18	29	8	1
6	27	43	5	2
7	31	48	7	3
8	23	35	7	4
9	22	34	5	4
10	28	36	6	4
11	29	45	6	4
12	27	43	7	2
13	28	44	5	3
14	28	44	7	3
15	28	44	8	3

Rozwiązanie 1 (1)

1) Jeden klaster.

Środek masy (reprezentant klastra)

i wartości min-max dla próbek:

$$m_0 = [23.7333 \quad 37.0667 \quad 7.2667];$$

$$\text{Min} = [16 \quad 27 \quad 5]$$



$$\text{Max} = [31 \quad 48 \quad 12]$$

$$\text{Odchyl. std.} = [5.4046 \quad 7.6855 \quad 1.9074]$$

2) Dwa klastry. Inicjalizacja reprezentantów:

$$m_1 = m_0 - (m_0 - \text{Min}) / 2 =$$
$$[19.8667 \quad 32.0333 \quad 6.1333]$$

$$m_2 = m_0 + (\text{Max} - m_0) / 2 =$$
$$[27.3667 \quad 42.5333 \quad 9.6333]$$



Rozwiązanie 1 (2)

2) Dwie klasy (c.d.)

Iterujemy:

- Klasyfikuj próbki
- Modyfikuj reprezentantów klastrów

Iteracja 1

$$m_1(1) = [18.5714 \quad 29.8571 \quad 8.2857]$$

$$m_2(1) = [28.2500 \quad 43.3750 \quad 6.3750]$$

Iteracja 2

Brak zmian \rightarrow Stop

3) Analiza

Kl. 1: 7 próbek, std duże \rightarrow podziel na 2

Kl. 2: 8 próbek, std duże \rightarrow podziel na 2

<i>Index</i>	0	1	2	Class Iter 1	ClassI ter 2
1	16	27	10	1	1
2	16	27	12	1	1
3	18	29	8	1	1
4	17	28	8	1	1
5	18	29	8	1	1
6	27	43	5	2	2
7	31	48	7	2	2
8	23	35	7	1	1
9	22	34	5	1	1
10	28	36	6	2	2
11	29	45	6	2	2
12	27	43	7	2	2
13	28	44	5	2	2
14	28	44	7	2	2
15	28	44	8	2	2

Rozwiązanie 1 (3)

4) Cztery klastry

Inicjalizacja

$$m_{1n} = m_1 - (m_1 - \text{Min}) / 2 =$$
$$[17.2857 \quad 28.4286 \quad 6.6429]$$


$$m_{2n} = m_1 + (m_0 - m_1) / 2 =$$
$$[21.1524 \quad 33.4619 \quad 7.7762]$$

$$m_{3n} = m_2 - (m_2 - m_0) / 2 =$$
$$[25.9917 \quad 40.2208 \quad 6.8208]$$

$$m_{4n} = m_2 + (\text{Max} - m_2) / 2 =$$
$$[29.6250 \quad 45.6875 \quad 9.1875]$$

Iteracja

- Klasyfikuj próbki
- Modyfikuj reprezentantów



Rozwiązanie 1 (4)

4) Cztery klastry (c.d.)

Iteracja 1

Liczba próbek w klastrze=[5 2 4 4]

$$m_1(1)=[17.0 \quad 28.0 \quad 9.2]$$

$$m_2(1)=[22.5 \quad 34.5 \quad 6.0]$$

$$m_3(1)=[27.5 \quad 41.5 \quad 5.75]$$

$$m_4(1)=[29.0 \quad 45.25 \quad 7.0]$$

Iteracja 2

Liczba próbek(klaster)= [5 2 3 5],

...

$$m_3(1)=[27.333 \quad 40.667 \quad 6.0]$$

$$m_4(1)=[28.8 \quad 45.0 \quad 6.6]$$

Iteracja 3: brak zmian → stop

Index	0	1	2	Class Iter 1	ClassI ter 2
1	16	27	10	1	1
2	16	27	12	1	1
3	18	29	8	1	1
4	17	28	8	1	1
5	18	29	8	1	1
6	27	43	5	3	3
7	31	48	7	4	4
8	23	35	7	2	2
9	22	34	5	2	2
10	28	36	6	3	2
11	29	45	6	4	2
12	27	43	7	3	3
13	28	44	5	3	4
14	28	44	7	4	4
15	28	44	8	4	4

Zadanie 2. Uczenie się drzewa decyzyjnego

– DTL i kryterium zysku informacji

Wykonać uczenie drzewa decyzyjnego metodą DTL (Quinlan ID3), w którym wybór testu (atrybutu) dokonuje się na podstawie **przyrostu (zysku) informacji**, dla podanego obok zbioru uczącego P .

Przeprowadzić niezbędne obliczenia.

Próbka x	Atrybut (Test) a_1	Atrybut (Test) a_2	Atrybut (Test) a_3	Klasa c
x_1	1	1	1	1
x_2	1	1	2	1
x_3	1	1	3	1
x_4	2	2	2	1
x_5	2	2	3	1
x_6	1	2	3	2
x_7	1	2	2	2
x_8	1	2	3	2
x_9	2	1	1	2
x_{10}	2	2	1	2

Rozwiązanie 2 (1)

Początkowa entropia: $H(P) = H([5/10, 5/10]) = 1.0$

1) Obliczenia dla korzenia drzewa P

Obliczamy entropię pozostałą dla zbioru P po zastosowaniu każdego z atrybutów (log oznacza logarytm o podstawie 2)

Dla atrybutu a1:

Dla $a1=1$ mamy 6 elementów (3 są klasy „1” i 3 klasy „2”), dla $a1=2$ mamy 4 elementy (2 są klasy „1” i 2 klasy „2”)

$$H_{\text{zostało}}(P \mid a1) = 6/10 (-3/6 \log(3/6) - 3/6 \log(3/6)) + \\ + 4/10 (-2/4 \log(2/4) - 2/4 \log(2/4)) = 6/10 * 1 + 4/10 * 1 = 1$$

Dla atrybutu a2:

Dla $a2=1$ mamy 4 elementy (z czego 3 są klasy „1” zaś 1 klasy „2”) oraz dla $a2=2$ mamy 6 elementów (z czego 2 są klasy „1” zaś 4 są klasy „2”)

$$H_{\text{zostało}}(P \mid a2) = 4/10 (-3/4 \log(3/4) - 1/4 \log(1/4)) + \\ + 6/10 (-2/6 \log(2/6) - 4/6 \log(4/6)) = 0.8755$$

Rozwiązanie 2 (2)

Dla atrybutu a3 :

Mamy 3 elementy „1” (z czego 1 jest klasy „1” zaś 2 klasy „2”), 3 elementy „2” (z czego 2 są klasy „1” zaś 1 klasy „2”), 4 elementy „3” (z czego 2 są klasy „1” zaś 2 są klasy „2”)

$$H_{\text{zostało}}(P \mid a3) = 3/10 (-1/3 \log(1/3) - 2/3 \log(2/3)) + 3/10 (-2/3 \log(2/3) - 1/3 \log(1/3)) + 4/10 (-2/4 \log(2/4) - 2/4 \log(2/4)) = 0.9510$$


Podsumowując, w korzeniu drzewa uzysk informacji (zmniejszenie niepewności) wynieść może:

$$ZI(P \mid a1) = 1 - 1 = 0.000$$

$$ZI(P \mid a2) = 1 - 0.8755 = 0.1245$$

$$ZI(P \mid a3) = 1 - 0.9510 = 0.049$$

Wniosek: Największy uzysk daje zastosowanie w korzeniu drzewa **atrybutu a2**.



Rozwiązanie 2 (3)

2) Węzły poziomu II

Określamy uzysk przy zastosowaniu pozostałych atrybutów a_1 i a_3 w węzłach $(a_2=1)$, $(a_2=2)$ powstałych dla wszystkich możliwych wartości atrybutu a_2 w korzeniu drzewa:

Węzeł $(a_2=1)$ - pozostały 4 elementy

Dla atrybutu a_1 mamy 3 elementy „ $a_1=1$ ” (klasy „1” są 3 i klasy 2 jest 0), oraz 1 element „ $a_1=2$ ” (z czego 0 jest klasy 1 i 1 jest klasy „2”)

$$H_{\text{zostało}}(a_2=1 \mid a_1) = \frac{3}{4} (-\frac{3}{3} \log \frac{3}{3}) + \frac{1}{4} (-\frac{2}{2} \log \frac{2}{2}) = 0$$

W zasadzie można już opuścić obliczenia dla a_3 , gdyż nie będzie większego zysku niż dla a_1 , ale mimo to sprawdźmy.

Rozwiązanie 2 (4)

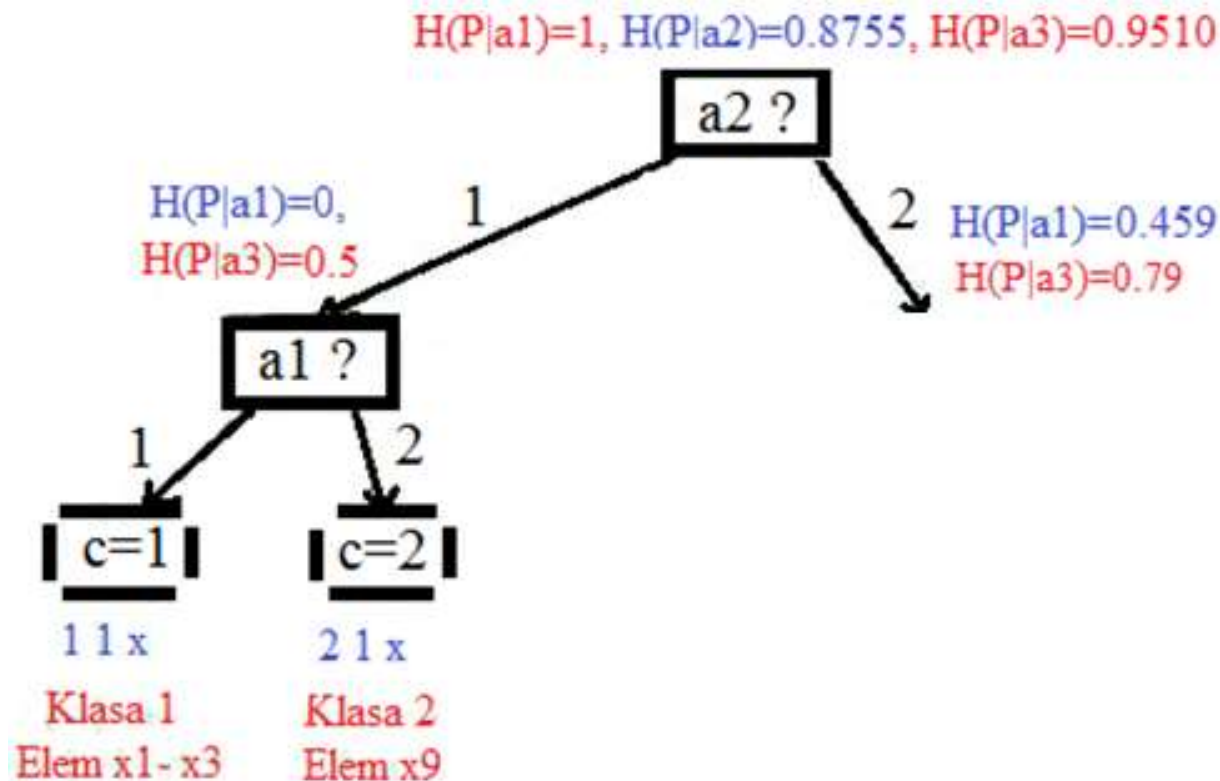
Dla atrybutu a_3 – mamy 2 elementy „1” (z czego 1 klasy „1” oraz 1 klasy „2”), 1 element „2” (klasy 1) i 1 element „3” klasy „1”

$$H_{\text{zostało}}(a_2=1 \mid a_3) = \frac{2}{4}(-\frac{1}{2} \log(\frac{1}{2}) - \frac{1}{2} \log(\frac{1}{2})) + \frac{1}{4}(-1 \log 1) + \frac{1}{4}(-1 \log 1) = \frac{2}{4} 2 * (-\frac{1}{2} * (-1)) + 0 + 0 = \frac{2}{4} * 1 = \frac{2}{4} = 0.5$$

Wniosek: Wybieramy w węźle ($a_2=1$) **atrybut a_1** .

Rozwiązanie 2 (4)

Na poziomie III z węzła ($a_2=1$) wychodzą już tylko dwa liście ($a_2=1, a_1=1$) i ($a_2=1, a_1=2$) (nie będą dalej analizowane), gdyż zawierają próbki wyłącznie jednej klasy – dla $a_1=1$ jest to klasa 1, a dla $a_1=2$ - klasa 2.



Rozwiązanie 2 (5)

- Węzeł (a2=2) - jest 6 elementów

Dla atrybutu a1 mamy 3 elementy „1” (wszystkie klasy 2), i 3 elementy „2” (z czego 1 jest klasy „1” oraz 2 elementy klasy „2”)

- $H_{\text{zostało}}(a2=2 \mid a1) = \frac{3}{6} (-1 \log 1) + \frac{3}{6} (-\frac{1}{3} \log (\frac{1}{3}) - \frac{2}{3} \log (\frac{2}{3})) = \frac{3}{6} * 0 + \frac{3}{6} * (\frac{1}{3} * 1.585 + \frac{2}{3} * 0.585) = \frac{1}{2} * 0.91835 = 0.45917$

Dla atrybutu a3 mamy 1 element „1” klasy „1” oraz 2 elementy „2” z czego 1 jest klasy „1” i 1 klasy „2” oraz 3 elementy „3” (1 klasy 1 i 2 klasy 2)

$$H_{\text{zostało}}(a2=2 \mid a3) = \frac{1}{6} (-1 \log 1) + \frac{2}{6} (-\frac{1}{2} \log(\frac{1}{2}) - \frac{1}{2} \log (\frac{1}{2})) + \frac{3}{6} (-\frac{1}{3} \log(\frac{1}{3}) - \frac{2}{3} \log (\frac{2}{3})) = 0 + \frac{2}{6} * 1 + \frac{1}{2} * 0.91835 = \frac{1}{3} = 0.79$$

Wniosek: atrybut a1 prowadzi do mniejszej entropii – daje większy uzysk – wybieramy a1 na węzeł poziomu II.

Rozwiązanie 2 (6)

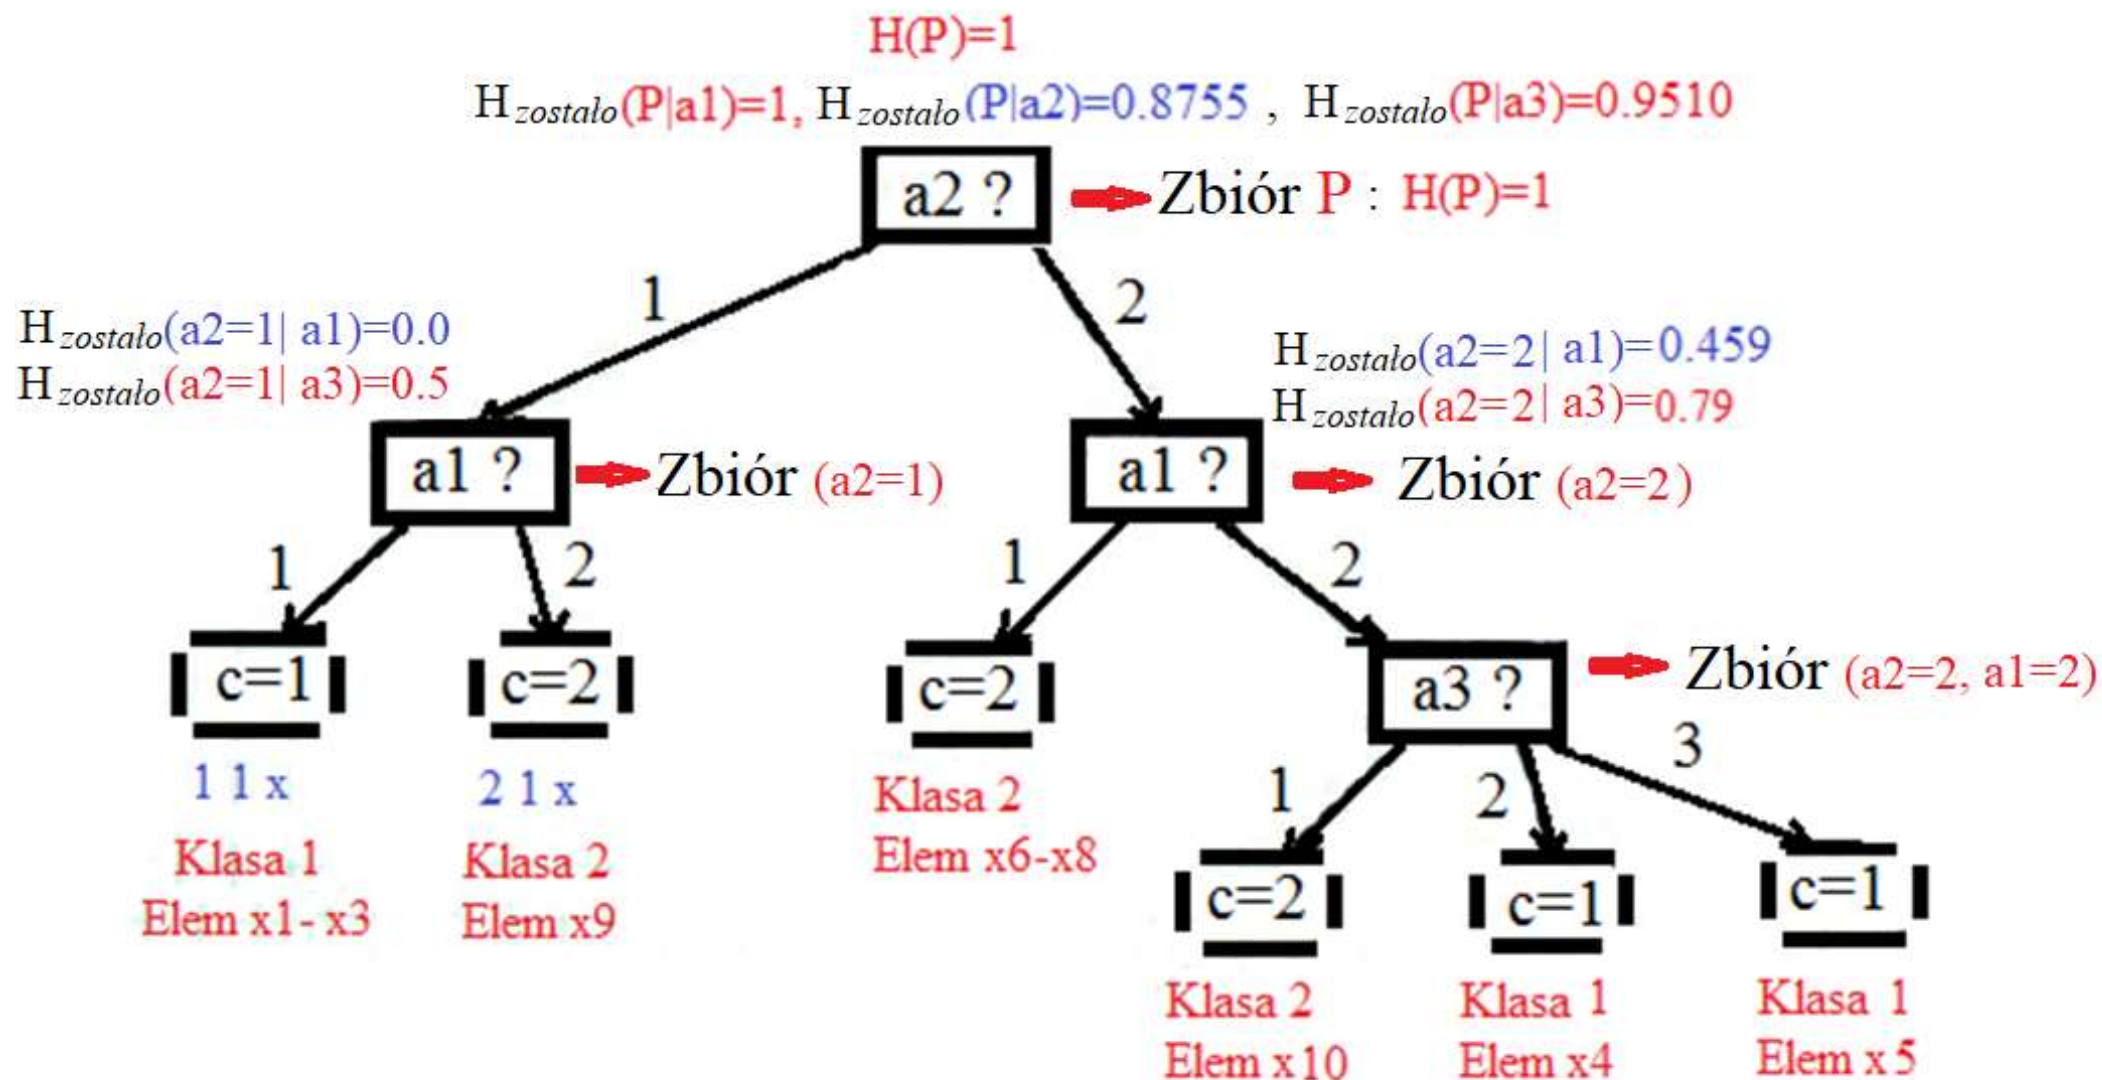
W tej gałęzi drzewa na poziomie III pozostaje już jedynie atrybut a_3 .

Jednak dla gałęzi ($a_2=2$, $a_1=1$), nie ma on znaczenia – wszystkie pozostałe tu elementy x_6 - x_8 są klasy 2.

Jedynie w gałęzi ($a_2=2$, $a_1=2$) dodany zostaje węzeł z testem a_3 . Oddziela on od siebie pozostałe elementy x_4 , x_5 , x_{10} .

Rozwiązanie 2 (7)

Powstało drzewo decyzyjne o postaci:



Zadanie 3. Uczenie się drzewa decyzyjnego

– DTL i iloraz zysku informacji

Wykonać uczenie drzewa decyzyjnego metodą DTL (Quinlan ID3), w którym wybór testu (atrybutu) dokonuje się na podstawie **ilorazu zysku informacji**, dla podanego obok zbioru uczącego P. Przeprowadzić niezbędne obliczenia.

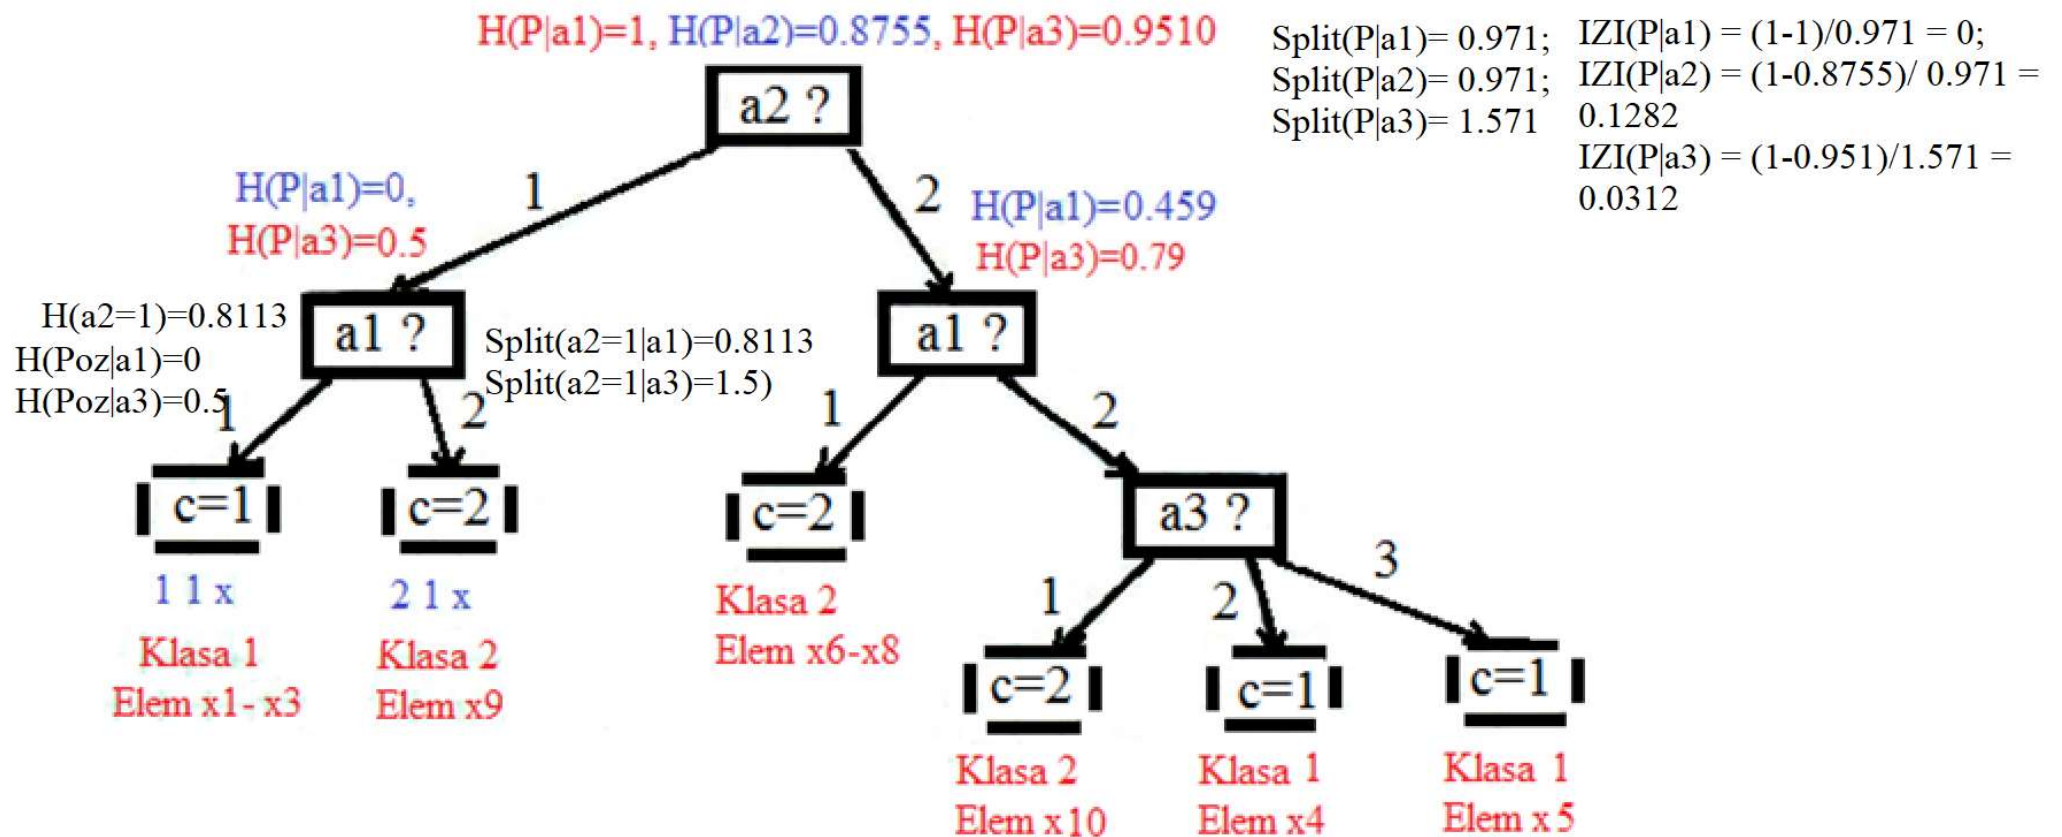
Porównać wynik z wynikiem zadania 2

Próbka x	Atrybut (Test) a1	Atrybut (Test) a2	Atrybut (Test) a3	Klasa c
x ₁	1	1	1	1
x ₂	1	1	2	1
x ₃	1	1	3	1
x ₄	2	2	2	1
x ₅	2	2	3	1
x ₆	1	2	3	2
x ₇	1	2	2	2
x ₈	1	2	3	2
x ₉	2	1	1	2
x ₁₀	2	2	1	2

Rozwiązanie 3

Musimy jawnie uwzględnić entropię każdego węzła w drzewie decyzyjnym, gdyż potrzebne jest porównanie zysku informacji normalizowanego entropią wartości każdego z atrybutów dla danego węzła ($\text{Split}(\text{węzeł} \mid \text{atrybut})$).

Okaże się, że drzewo decyzyjne w porównaniu z rozwiązaniem poprzedniego zadania nie ulegnie zmianie.



Zadanie 4. Klasyfikator ML i Bayesa

Nad przestrzenią cech \mathcal{R}^2 ustalić należy (graficznie i analitycznie) rozkłady 3 klas, uwzględniając następujących 10 próbek uczących:

$c_k=(x, y)$	(1; 2,5)	(0.5; 3)	(0; 3,5)	(2; 3)	(4; 4)	(3; 5)	(1; 1)	(2; 0)	(3; 1)	(2; 2)
Klasa Ω	1	1	1	2	2	2	3	3	3	3

(A) Podać wyniki uczenia dla 3 klasyfikatorów:

- 1) klasyfikatora geometrycznego minimalnej odległości,
- 2) klasyfikatora ML (największej wiarygodności)
- 3) klasyfikatora Bayesa.

(W klasyfikatorach ML i Bayesa przyjąć rozkłady Gaussa prawdopodobieństw warunkowych a priori)

(B) Podać wyniki klasyfikacji próbki (2; 2,5) w powyższych klasyfikatorach

Rozwiązanie 4 (1)

A)

1) Klasyfikator geometryczny

Centroidy (μ_i) obszarów klas:

2) Klasyfikator ML.

Klasa „i”	μ_i
1	(0.5; 3)
2	(3; 4)
3	(2; 1)

Rozkłady warunkowe apriori: $p(c \mid \text{klasa}_i) = N(\mu_i, \Sigma_i)$, $i = 1, 2, 3$

Klasa „i”	μ_i	Σ (2D) lub σ_r (1D)	Σ^{-1} (macierz odwrotna)
1	(1/2; 3)	1-wymiarowy: $\sigma_r^2 = 1/3$ 2D: $\Sigma = \begin{bmatrix} 1/6 & -1/6 \\ -1/6 & 1/6 \end{bmatrix}$	UWAGA: $\det(\Sigma) = 0$! Zastosować rozkład 1D zmiennej r: $\exp(-1/2 (r^2)/\sigma_r^2)$
2	(3, 4)	1-wymiarowy: $\sigma_r^2 = 4/3$ 2D: $\Sigma = \begin{bmatrix} 2/3 & 1/3 \\ 1/3 & 2/3 \end{bmatrix}$	$\det(\Sigma) = 0.3333$ $\Sigma^{-1} = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}$
3	(2; 1)	1-wymiarowy: $\sigma_r^2 = 1$ 2D: $\Sigma = \begin{bmatrix} 1/2 & 0 \\ 0 & 1/2 \end{bmatrix}$	$\det(\Sigma) = 0.25$ $\Sigma^{-1} = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$

Rozwiązanie 4 (2)

Dla klasy 1 rozkład 2D jest zdegenerowany – wyznacznik macierzy Σ_1 wynosi zero - musimy zastąpić rozkład 2D rozkładem 1D nowej zmiennej „ $r(c)$ ” – odlegością punktu c od centroidy (środka masy) punktów danej klasy. W celu uczciwego porównywania wyników klasyfikacji dla trzech klas określimy 1-wymiarowe rozkłady warunkowe a priori dla wszystkich trzech klas:

$$r_i(c) = \|c - \mu_i\|, i = 1, 2, 3$$

$$r_i([x, y]) = \sqrt{(x - \mu_i)^2 + (y - \mu_i)^2}$$

Otrzymamy rozkłady warunkowe a priori zmiennej r :

$$p_i(r | \mu_i, \sigma_i) = N(0, \sigma_i), i = 1, 2, 3$$

$$N(0, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \cdot \exp\left(-\frac{r^2}{2\sigma^2}\right)$$

Wyznaczamy wartości $r^2(c_k)$:

$c_k=(x, y)$	(1; 2.5)	(0.5; 3)	(0; 3.5)	(2; 3)	(4; 4)	(3; 5)	(1; 1)	(2; 0)	(3; 1)	(2; 2)
μ_i	(0.5; 3)	(0.5; 3)	(0.5; 3)	(3; 4)	(3; 4)	(3; 4)	(2; 1)	(2; 1)	(2; 1)	(2; 1)
r_k^2	0.5	0	0.5	2	1	1	1	1	1	1

Rozwiązanie 4 (3)

Stąd wariancje rozkładów dla trzech klas wynoszą:

$$\sigma_1^2(r) = \frac{1}{3}(0.5 + 0 + 0.5) = \frac{1}{3}$$

$$\sigma_2^2(r) = \frac{1}{3}(2 + 1 + 1) = \frac{4}{3}$$

$$\sigma_3^2(r) = \frac{1}{4}(1 + 1 + 1 + 1) = 1$$

3) Klasyfikator Bayesa

Dodatkowo do definicji rozkładów warunkowych a priori, jak dla klasyfikatora ML powyżej, potrzebny jest rozkład a priori prawdopodobieństwa klas:

$$p(\text{klasa}) = [3/10, 3/10, 4/10] .$$

Rozwiązanie 4 (4)

B) Klasyfikacja próbki, $c = (2, 2.5)$

1) Klasyfikator geometryczny z miarą euklidesową:

- Klasa 1: $r_1^2(c) = |(2, 2.5) - (0.5, 3)| = 1.5^2 + 0.5^2 = 2.25 + 0.25 = 2.5$
- Klasa 2: $r_2^2(c) = |(2, 2.5) - (3, 4)| = 1 + 1.5^2 = 3.25$
- Klasa 3: $r_3^2(c) = |(2, 2.5) - (2, 1)| = 0 + 1.5^2 = 2.25$

Reguła decyzyjna: $\arg \min_i r_i^2 = \arg \min [2.5, 3.25, 2.25] = 3$

Zwycięża klasa 3.

2) Klasyfikator ML.

Reguła decyzyjna:

$$\arg \max_i p_i(r_i(c) | (0, \sigma_i))$$
$$\arg \max_i \frac{1}{\sigma_i \sqrt{2\pi}} \cdot \exp\left(-\frac{r_i^2}{2\sigma_i^2}\right) = \frac{1}{\sqrt{2\pi}} \arg \max_i \frac{1}{\sigma_i} \cdot \exp\left(-\frac{r_i^2}{2\sigma_i^2}\right)$$

Dla klasy 1: $0.02351 \cdot 1.732 = 0.040719$

gdzie

$$\exp\left(-\frac{2.5}{2/3}\right) = \exp(-3.75) \cong 0.02351 \quad \frac{1}{\sigma_1} = \frac{1}{\sqrt{1/3}} \cong 1.732$$

Rozwiązanie 4 (5)

Dla klasy 2: $0.2956 \cdot 0.866 = 0.2559896$

gdzie $\exp\left(-\frac{3.25}{2 \cdot \frac{4}{3}}\right) = \exp(-1.21875) \cong 0.2956$ $\frac{1}{\sigma_2} = \frac{1}{\sqrt{\frac{4}{3}}} \cong 0.866$

Dla klasy 3: $0.3246 \cdot 1 = 0.3246$

gdzie $\exp\left(-\frac{2.25}{2 \cdot 1}\right) = \exp(-1.125) \cong 0.3246$ $\frac{1}{\sigma_r} = \frac{1}{\sqrt{1}} = 1$

Stąd: $\arg \max_i [0.04071, 0.25599, 0.32460] = 3$

Zwycięża klasa 3.

3) Klasyfikator Bayesa

Uwzględniamy dodatkowo do ML rozkład a priori klas: $p(i) = [0.3, 0.3, 0.4]$

Stąd: $\arg \max_i [0.3 \cdot 0.04071, 0.3 \cdot 0.25599, 0.4 \cdot 0.32460] = 3$

Zwycięża klasa 3.

Zadanie 5. Klasyfikator k-NN

Nad przestrzenią cech \mathcal{R}^2 ustalić należy (graficznie) rozkłady 4 klas, uwzględniając następujących 11 próbek uczących:

(x,y)	(1;2,5)	(1; 3)	(1;3,5)	(2; 3)	(4; 3)	(2; 2)	(1; 1)	(2; 0)	(3; 1)	(3,5;1,5)	(4; 1,5)
Klasa	1	1	1	2	2	3	3	3	3	4	4

- (A) Narysować diagram Voronoia uzyskany w procesie uczenia klasyfikatora według $k=4$ sąsiadów (4-NN).
- (B) Podać wynik klasyfikacji wektora cech (2; 2,5) w tym klasyfikatorze.

Zadanie 6. Klasyfikator SVM

- A) Zdefiniować problem uczenia klasyfikatora SVM dla podanego niżej zbioru 2-wymiarowych cech i dwóch klas,
- B) Podać spodziewane w tym przypadku rozwiązanie w graficzny sposób,
- C) Rozwiązać problem analitycznie lub algorytmicznie i podać dokładne rozwiązanie.

Zadany jest następujący zbiór próbek uczących:

Indeks „i”	1	2	3	4	5	6
$C_i = (c_{i1}, c_{i2})$	(2; 2)	(1; 4)	(1; 6)	(2; 1)	(4; 2)	(5; 2)
Klasa $\Omega_k =$	Ω_1	Ω_1	Ω_1	Ω_2	Ω_2	Ω_2

Rozwiązanie 6 (1)

A) Postać pierwotna („prymalna”) problemu optymalizacji dla procesu uczenia liniowego klasyfikatora SVM.

Minimalizacja kwadratowej funkcji celu: $\frac{1}{2} \mathbf{a}^T \mathbf{a}$

przy ograniczeniach liniowych: $y_i(\mathbf{a}^T \cdot \mathbf{c}_i + a_0) \geq 1; i = 1, \dots, N$

Gdzie $\mathbf{a} = (a_1, a_2, \dots, a_n)$ – wektor normalny do hiperpłaszczyzny.

Szukane parametry: wektor normalny \mathbf{a} i wyraz wolny a_0 .

W tym zadaniu konkretnie: $n = 2, h=3 \rightarrow \hat{\mathbf{a}} = (a_0, a_1, a_2), \mathbf{a} = (a_1, a_2)$

$N=6$ próbek: $i = 1, 2, \dots, 6$.

Optymalizacja oznacza, że przy zadanych ograniczeniach maksymalizowany jest też „margines rozwiązania”: $\tau = 1 / |\mathbf{a}|$.


Hiperpłaszczyzna – w tym przypadku prosta skierowana – separuje obszary 2 klas w przestrzeni cech: $H(\mathbf{c}): a_0 + \mathbf{a}^T \mathbf{c} = 0$, gdzie wektor cech $\mathbf{c} = (c_1, c_2)$.

Rozwiązanie 6 (2)

B) Rozwiązanie graficzne

Poszukujemy 3 wektorów wspierających: 2 z nich należą do jednej klasy a 1 do klasy drugiej. Wyznaczają one dwie wzajemnie równoległe proste wspierające: $H_{+1}(c) = 1$, i $H_{-1}(c) = -1$. Pomiedzy tymi prostymi nie leżą żadne inne próbki uczące.

Odstęp pomiędzy prostymi jest największy spośród możliwych rozwiązań tego typu.



Rozwiązanie 6 (3)

C) Rozwiązanie analityczne – wykorzystamy rozwiązanie ogólnego problemu programowania kwadratowego

Np. funkcja **quadprog** w MATLAB-ie służy do rozwiązywania ogólnego problemu optymalizacji kwadratowej o postaci:

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x}} \frac{1}{2} \mathbf{x}^T \mathbf{H} \mathbf{x} + \mathbf{f}^T \mathbf{x}$$

przy ograniczeniach: $\mathbf{A} \mathbf{x} \leq \mathbf{b}$.

Szukany jest wektor \mathbf{x} .

Aby wyrazić problem uczenia klasyfikatora SVM jako specyficzne **quadprog** należy zdefiniować macierze \mathbf{H} , \mathbf{A} i wektory \mathbf{f} , \mathbf{b} ,

dla wywołania funkcji: $\mathbf{x} = \mathbf{quadprog}(\mathbf{H}, \mathbf{f}, \mathbf{A}, \mathbf{b})$.

Problem uczenia klasyfikatora SVM przedstawimy jako minimalizację funkcji o postaci:

przy czym:

$$\mathbf{x} = \begin{pmatrix} a_1 \\ a_2 \\ a_0 \end{pmatrix} \quad \mathbf{H} = \begin{pmatrix} \mathbf{I}_n & 0 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix} \quad \mathbf{f} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$$
$$\frac{1}{2} [\mathbf{a} \ a_0] \begin{pmatrix} \mathbf{I}_n & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} \mathbf{a} \\ a_0 \end{pmatrix} + (0 \ 0 \ 0) \begin{pmatrix} a_1 \\ a_2 \\ a_0 \end{pmatrix}$$

Rozwiązanie 6 (4)

Ograniczenia dla $n=2$ i $N=6$ przyjmują postać:

$$\begin{pmatrix} y_1 & 0 & 0 & 0 \\ 0 & y_2 & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & y_N \end{pmatrix} \begin{pmatrix} {}^1c_1 & {}^1c_2 & 1 \\ {}^2c_1 & {}^2c_2 & 1 \\ \dots & \dots & \dots \\ {}^Nc_1 & {}^Nc_2 & 1 \end{pmatrix} \begin{pmatrix} a_1 \\ a_2 \\ \dots \\ a_0 \end{pmatrix} \geq \begin{pmatrix} 1 \\ 1 \\ \dots \\ 1 \end{pmatrix}$$

gdzie

$$\mathbf{A} = - \begin{pmatrix} y_1 & 0 & 0 & 0 \\ 0 & y_2 & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & y_N \end{pmatrix} \begin{pmatrix} {}^1c_1 & {}^1c_2 & 1 \\ {}^2c_1 & {}^2c_2 & 1 \\ \dots & \dots & \dots \\ {}^Nc_1 & {}^Nc_2 & 1 \end{pmatrix} \quad \mathbf{b} = - \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{pmatrix}$$

Podstawiając próbki uczące otrzymamy konkretnie:

$$\mathbf{A} = - \begin{pmatrix} 1 & & & & & \\ & 1 & & & & \\ & & 1 & & & \\ & & & -1 & & \\ & & & & -1 & \\ & & & & & -1 \end{pmatrix} \begin{pmatrix} 2 & 2 & 1 \\ 1 & 4 & 1 \\ 1 & 6 & 1 \\ 2 & 1 & 1 \\ 4 & 2 & 1 \\ 5 & 2 & 1 \end{pmatrix} \quad \mathbf{A} = - \begin{pmatrix} 2 & 2 & 1 \\ 1 & 4 & 1 \\ 1 & 6 & 1 \\ -2 & -1 & -1 \\ -4 & -2 & -1 \\ -5 & -2 & -1 \end{pmatrix} = \begin{pmatrix} -2 & -2 & -1 \\ -1 & -4 & -1 \\ -1 & -6 & -1 \\ 2 & 1 & 1 \\ 4 & 2 & 1 \\ 5 & 2 & 1 \end{pmatrix}$$

Rozwiązanie 6 (5)

Rozwiązanie: $\mathbf{x} = [-1, 2, -1]$, tzn. $a_1 = -1$, $a_2 = 2$, $a_0 = -1$

Równanie prostej separującej: $H(\mathbf{c}): -1 + (-1) c_1 + 2 c_2 = 0$

Margines wynosi: $\tau = \frac{1}{\|\mathbf{a}\|} = \frac{1}{\sqrt{5}} \approx 0.447$

Zadanie 7. SVM – wybór i porównanie rozwiązań

Zakładamy zbiór uczący dla klasyfikatora SVM w postaci:

j	1	2	3	4	5	6
$\mathbf{c}^j = (c_1, c_2)$	(0; 1)	(1; 3)	(2; 6)	(2; 1)	(3; 3)	(4; 4.5)
Class	1	1	1	-1	-1	-1

Założmy hipotezy istnienia dwóch zbiorów wektorów nośnych klasyfikatora SVM:

$$\mathbf{A} = \{(0, 1), (1, 3), (3, 3)\}; \quad \mathbf{B} = \{(3, 3), (4, 4.5), (0, 1)\}.$$


Należy sprawdzić, który z tych zbiorów stanowi potencjalne rozwiązanie klasyfikatora SVM.

Zilustrować rozwiązania graficznie.

Wskazówka: należy znaleźć równania prostych separujących, sprawdzić marginesy rozwiązań i spełnianie ograniczeń.

Rozwiązanie 7 (1)

Zbiór próbek uczących:



Rozwiązanie 7 (2)

Zbiór A

1) Prosta separująca

Ograniczenia dla „wektorów nośnych” dają układ trzech równań:

$$y_i(\mathbf{a}^T \cdot \mathbf{c} + a_0) = 1; \quad i = 1, 2, 3.$$

$$\begin{cases} 1 \cdot ([a_1 \ a_2] \cdot \begin{bmatrix} 0 \\ 1 \end{bmatrix} + a_0) = 1 \\ 1 \cdot ([a_1 \ a_2] \cdot \begin{bmatrix} 1 \\ 3 \end{bmatrix} + a_0) = 1 \\ -1 \cdot ([a_1 \ a_2] \cdot \begin{bmatrix} 3 \\ 3 \end{bmatrix} + a_0) = 1 \end{cases}$$

Rozwiązanie 7 (3)

$$\begin{bmatrix} 1 & 0 & 1 \\ 1 & 1 & 3 \\ -1 & -3 & -3 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 0 & 1 \\ 1 & 1 & 3 \\ -1 & -3 & -3 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

$$\begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 1 \\ 1 & 1 & 3 \\ -1 & -3 & -3 \end{bmatrix}^{-1} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

$$\begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} 0.5 \\ -1 \\ 0.5 \end{bmatrix}$$

Rozwiązanie 7 (4)

Stąd równanie prostej skierowanej

$$H^*(\mathbf{c}) : -1c_1 + \frac{1}{2}c_2 + \frac{1}{2} = 0$$

Graficznie - linia w układzie x-y:

$$y = 2x - 1$$

2) Margines rozwiązania

$$d = \frac{1}{|\mathbf{a}|} = \frac{1}{\sqrt{(-1)^2 + 0.5^2}} = \frac{2}{\sqrt{5}} \approx 0.8944$$

3) Sprawdzenie ograniczeń:

Nr	Próbka (c_1, c_2)	$a_1c_1 + a_2c_2 + a_0 = ?$	Powinno być	Ograniczenie spełnione?
1	(0,1)	1	= 1	True
2	(1,3)	1	= 1	True
3	(2,6)	1.5	≥ 1	True
4	(2,1)	-1	≤ -1	True
5	(3,3)	-1	= -1	True
6	(4, 4.5)	-1.25	≤ -1	True

Rozwiązanie 7 (6)

Zbiór B

1) Równanie prostej separującej

$$\begin{cases} -1 \cdot ([a_1 \ a_2] \cdot \begin{bmatrix} 3 \\ 3 \end{bmatrix} + a_0) = 1 \\ -1 \cdot ([a_1 \ a_2] \cdot \begin{bmatrix} 4 \\ 4.5 \end{bmatrix} + a_0) = 1 \\ 1 \cdot ([a_1 \ a_2] \cdot \begin{bmatrix} 0 \\ 1 \end{bmatrix} + a_0) = 1 \end{cases}$$

$$\begin{bmatrix} -1 & -3 & -3 \\ -1 & -4 & -4.5 \\ 1 & 0 & 1 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \rightarrow \boxed{\begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} 0.2 \\ -1.2 \\ 0.8 \end{bmatrix}}$$

Rozwiązanie 7 (7)

Prosta $H^*(c)$:

$$-1\frac{1}{5}c_1 + \frac{4}{5}c_2 + \frac{1}{5} = 0$$

Graficznie w układzie x-y:

$$y = 1.5x - 0.25$$

2) „Margines” rozwiązania:

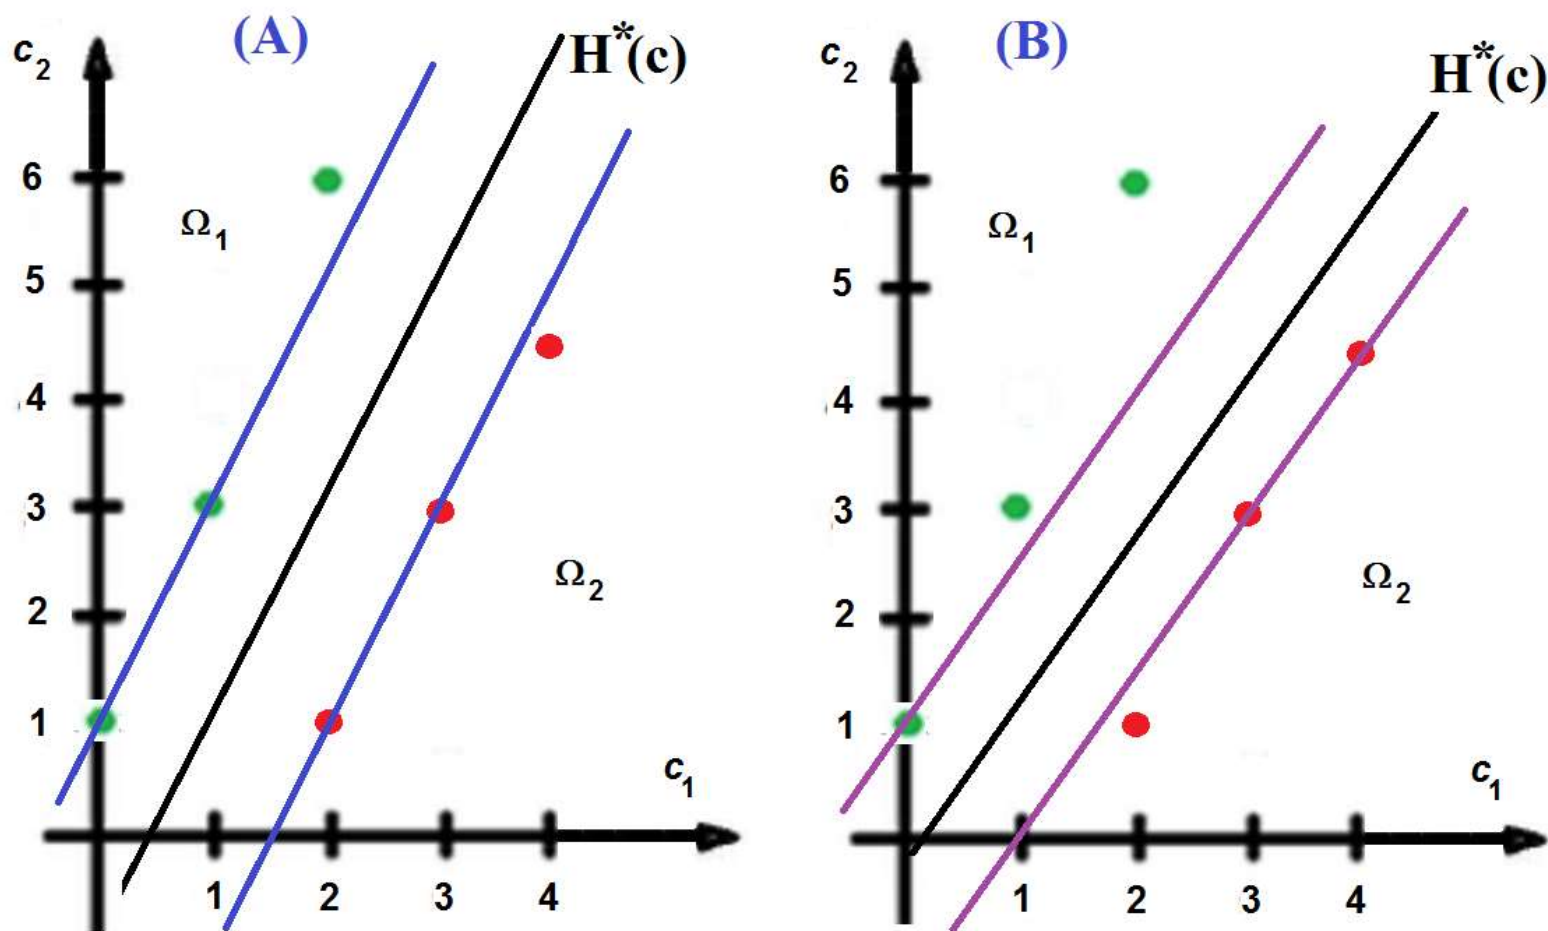
$$d = \frac{1}{|\mathbf{a}|} = \frac{1}{\sqrt{\left(\frac{-6}{5}\right)^2 + \left(\frac{4}{5}\right)^2}} = \frac{5}{\sqrt{52}} \approx 0.6934$$

3) Sprawdzenie ograniczeń

Nr	Próbka (c_1, c_2)	$a_1c_1 + a_2c_2 + a_0 = ?$	Powinno być	Ograniczenie spełnione?
1	(0,1)	1	= 1	True
2	(1,3)	1.4	≥ 1	True
3	(2,6)	2.6	≥ 1	True
4	(2,1)	-1.4	≤ -1	True
5	(3,3)	-1	= -1	True
6	(4, 4.5)	-1	≤ -1	True

Rozwiązanie 7 (5)

Ilustracja obu hipotetycznych rozwiązań:



Rozwiązanie 7 (8)

Odpowiedź

Oba zbiory wyznaczają rozwiązania spełniające ograniczenia, ale zbiór A wyznacza rozwiązanie o większym „marginesie”.

Dlatego potencjalnym rozwiązaniem jest zbiór A.

Zad. 8. Klasyfikator SVM „zakłócany szumem” – analiza możliwych rozwiązań

Zaproponować prostą metodę sprawdzania “zbiorów kandydatów na wektory nośne” dla klasyfikatora SVM, tzn. po wybraniu odpowiedniej liczby próbek ze zbioru uczącego należy znaleźć rozwiązanie (równanie hiperpłaszczyzny $H(\mathbf{c})$), wyznaczyć „margines rozwiązania”, sprawdzić spełnianie ograniczeń (ewentualnie określić i dodać wartość kary ε w przypadku niespełniania ograniczenia przez próbkę).

Kryterium uczenia **klasyfikatora SVM („zakłócanego szumem”)**

wynosi:

$$\min_{\tilde{\mathbf{a}} \in R^{n+1}} f(\tilde{\mathbf{a}}) = \min_{\mathbf{a} \in R^n} \left(\frac{1}{2} |\mathbf{a}|^2 + C \sum_{j=1}^N \varepsilon_j \right)$$


Założyć, że współczynnik kary C wynosi 1, a zbiór uczący obejmuje 6 poniższych próbek (po 3 w klasach $+1$ i -1), w przestrzeni cech \mathcal{R}^2 :

$\mathbf{c}=(c_1, c_2)$	(1; 2)	(1; 3)	(1; 4)	(1; 1)	(2; 1)	(3; 1)
Klasa	+1	+1	+1	-1	-1	-1

Rozw. 8. Analiza rozwiązań „wektorów nośnych” (1)

Ponieważ rozmiar przestrzeni cech, $n=2$, poszukujemy zbioru 3 ($h=n+1$) „wektorów nośnych”, z których 2 próbki należą do jednej klasy a jedna do drugiej.

A) Jeśli przyjmiemy, że **dwie próbki należą do klasy „+1”** to każda ich kombinacja (2 próbek z 3 możliwych) daje hiperpłaszczyznę wspierającą „+1” o równaniu $c_1 = 1$. Możliwe jest dobranie jednego z trzech punktów klasy „-1”.



Rozwiązanie 8 (2)

- Jeśli dobierzemy próbkę $[1, 1]$ to margines rozwiązania wyniesie 0 (obie proste wspierające pokrywają się), ale wszystkie ograniczenia będą spełnione. Jednak: $f(\tilde{\mathbf{a}}^{(1)}) = \infty$

- Jeśli dobierzemy próbkę $[2, 1]$ to $H(\mathbf{c})$: $-2 \cdot c_1 + 0 \cdot c_2 + 3 = 0$.

Margines rozwiązania wyniesie 0.5, ale dla próbki $[1, 1]$ nie będzie spełnione ograniczenie: $H([1, 1])=1$, czyli $-1 \cdot 1 = 1 - \varepsilon \Rightarrow \varepsilon = 2$.

Kara wyniesie $C \cdot \varepsilon = 2$, a funkcja celu: $f(\tilde{\mathbf{a}}^{(2)}) = \frac{1}{2} \cdot 2^2 + 2 = 4$

- Jeśli dobierzemy próbkę $[3, 1]$ to $H(\mathbf{c})$: $-1 \cdot c_1 + 0 \cdot c_2 + 2 = 0$.

Margines rozwiązania wyniesie 1.0, ale dla próbek $[1, 1]$ i $[2, 1]$ nie będzie spełnione ograniczenie:

$H([1, 1]) = 1$, czyli $-1 \cdot 1 = 1 - \varepsilon_1 \Rightarrow \varepsilon_1 = 2$;

$H([2, 1]) = 0$, czyli $-1 \cdot 0 = 1 - \varepsilon_2 \Rightarrow \varepsilon_2 = 1$.

Funkcja celu: $f(\tilde{\mathbf{a}}^{(3)}) = \frac{1}{2} \cdot 1^2 + 3 = 3.5$

Rozwiązanie 8 (3)

B) Jeśli przyjmiemy, że **dwie próbki należą do klasy „-1”** to w tym przypadku każda ich kombinacja (2 próbek z 3 możliwych) daje prostą wspierającą „-1” o równaniu $c_2 = 1$. Możliwe jest dobranie jednego z trzech punktów klasy „+1”.

B1) Niech zbiór próbek-kandydatów jest następujący:

$$^1\mathbf{c} = (1,2) , \text{ klasy } +1$$

$$^2\mathbf{c} = (1,1), \text{ klasy } -1$$

$$^3\mathbf{c} = (2,1), \text{ klasy } -1$$

Pomimo, że rozwiązanie w przypadku klasycznego liniowego SVM jest dla nas oczywiste, rozwiążemy jednak ten przypadek w sposób ogólny, dla ilustracji potrzebnego nam algorytmu, a także uwzględnimy rozwiązania nie spełniające wszystkich ograniczeń.

Rozwiązanie 8 (4)

Równanie prostej skierowanej znajdujemy analogicznie jak w zadaniu 6. Ma ono postać, $H^*(\mathbf{c})$: $0 c_1 + 2 c_2 - 3 = 0$

Alternatywnie możemy rozwiązać problem poprzez mnożniki Lagrange'a, korzystając z własności SVM, że hiperpłaszczyzna rozdzielająca obszary klas zadana jest sumą iloczynów skalarnych danej próbki (tu: kolejnych punktów ze zbioru kandydatów) z kandydatami na „wektory nośne”:

$$d_{\Lambda, a_0}(\mathbf{c}^1) = \sum_{j=1}^3 \lambda_j y_j (\mathbf{c}^1{}^T \mathbf{c}^j) + a_0 = y^1$$

Niezbędne jest tu dodanie jednego równania, gdyż nieznane jest także a_0 .

$$d_{\Lambda, a_0}(\mathbf{c}^2) = \sum_{j=1}^3 \lambda_j y_j (\mathbf{c}^2{}^T \mathbf{c}^j) + a_0 = y^2$$

Korzystamy z ograniczenia o ważonej sumie mnożników Lagrange'a równej zero.

$$d_{\Lambda, a_0}(\mathbf{c}^3) = \sum_{j=1}^3 \lambda_j y_j (\mathbf{c}^3{}^T \mathbf{c}^j) + a_0 = y^3$$

$$\sum_{j=1}^3 \lambda_j y_j = 0$$

Rozwiązanie 8 (5)

Po podstawieniu danych otrzymujemy układ 4 równań z 4 niewiadomymi:

$$\lambda_1 (1,2)^T (1,2) - \lambda_2 (1,2)^T (1,1) - \lambda_3 (1,2)^T (2,1) + a_0 = 1$$

$$\lambda_1 (1,1)^T (1,2) - \lambda_2 (1,1)^T (1,1) - \lambda_3 (1,1)^T (2,1) + a_0 = -1$$

$$\lambda_1 (2,1)^T (1,2) - \lambda_2 (2,1)^T (1,1) - \lambda_3 (2,1)^T (2,1) + a_0 = -1$$

$$\lambda_1 - \lambda_2 - \lambda_3 = 0$$

Po wymnożeniu wektorów układ równań ma postać:

$$\lambda_1 5 - \lambda_2 3 - \lambda_3 4 + a_0 = 1$$

$$\lambda_1 3 - \lambda_2 2 - \lambda_3 3 + a_0 = -1$$

$$\lambda_1 4 - \lambda_2 3 - \lambda_3 5 + a_0 = -1$$

$$\lambda_1 - \lambda_2 - \lambda_3 = 0$$

Rozwiązanie układu (mnożniki Lagrange'a λ_i i a_0):

$$\bullet \quad \lambda_1 = 2, \quad \lambda_2 = 2, \quad \lambda_3 = 0, \quad a_0 = -3$$

Rozwiązanie 8 (6)

Z warunku K-K-T, na podstawie znanych mnożników Lagrange'a wyliczamy współczynniki kierunkowe szukanej prostej, $\mathbf{a} = (a_1, a_2)^T$:

$$\mathbf{a} = \sum_{j=1}^3 y_j \lambda_j^j \mathbf{c}$$

$$\begin{bmatrix} a_1 \\ a_2 \end{bmatrix} = 2 \begin{bmatrix} 1 \\ 2 \end{bmatrix} - 2 \begin{bmatrix} 1 \\ 1 \end{bmatrix} - 0 \begin{bmatrix} 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 2 \end{bmatrix}$$

Stąd równanie prostej separującej ma postać:

$$0 c_1 + 2 c_2 - 3 = 0$$

„Margines” tego rozwiązania:

$$d = \frac{1}{\|\mathbf{a}\|} = \frac{1}{\sqrt{a_1^2 + a_2^2}} = \frac{1}{\sqrt{0^2 + 2^2}} = \frac{1}{2}$$

Sprawdzamy ograniczenia dla tego rozwiązania \rightarrow

Rozwiązanie 8 (7)

Sprawdzamy ograniczenia dla tego rozwiązania:

Nr	$\mathbf{c}=(c_1, c_2)$	$a_1c_1+a_2c_2 + a_0 = ?$	Powinno być	Błąd ε
1	(1,2)	1	$= 1$	0
2	(1,3)	3	≥ 1	0
3	(1,4)	5	≥ 1	0
4	(1,1)	-1	$= -1$	0
5	(2,1)	-1	$= -1$	0
6	(3,1)	-1	≤ -1	0

Wartość funkcji celu:

$$f(\tilde{\mathbf{a}}^{(4)}) = \frac{1}{2} \cdot 2^2 + 0.0 = 2.0$$

Rozwiązanie 8 (8)

Analogicznie znajdujemy i sprawdzamy pozostałe dwa zbiory potencjalnych wektorów nośnych:

(obliczenia pominięto).

Pozostałe zbiory - próbka klasy „+1” wynosi:

- ${}^1c = (1,3) \rightarrow \boxed{f(\tilde{a}^{(5)}) = \frac{1}{2} \cdot 1^2 + 1 = 1.5} \rightarrow \text{najlepsze rozwiązanie!}$

lub

- ${}^1c = (1,4) \rightarrow \boxed{f(\tilde{a}^{(6)}) = \frac{1}{2} \cdot \frac{2}{3}^2 + (\frac{2}{3} + \frac{4}{3}) = 2.222}$

Zadanie 9. Regresja liniowa

Wyznaczyć aproksymację liniową funkcji, $y=f(x)$, w oparciu o poniższy zbiór próbek (x_i, y_i) ($i=1,2,\dots,6$).

i	1	2	3	4	5	6
x	1	1	1	1	2	3
y	2	3	4	1	1	1

Rozwiązanie 9. Regresja liniowa

Idea rozwiązania.

Rozwiązanie problemu metodą najmniejszych kwadratów (MNK) .
Poszukiwana jest funkcja liniowa o postaci parametrycznej:

$$y = f(x | a, b) = a x + b$$

Początkowy układ 6 równań dla zadanych próbek uczących:

$$a \cdot 1 + b = 2 + \varepsilon_1 ; \quad a \cdot 1 + b = 3 + \varepsilon_2$$

$$a \cdot 1 + b = 4 + \varepsilon_3 ; \quad a \cdot 1 + b = 1 + \varepsilon_4$$

$$a \cdot 2 + b = 1 + \varepsilon_5 ; \quad a \cdot 3 + b = 1 + \varepsilon_6$$

Sumaryczna funkcja błędu: $U(a, b) = \varepsilon_1^2 + \varepsilon_2^2 + \varepsilon_3^2 + \varepsilon_4^2 + \varepsilon_5^2 + \varepsilon_6^2$

Jest to funkcja kwadratowa względem a , b . Poszukiwane minimum znajdujemy w punkcie o zerowych pochodnych cząstkowych funkcji U względem nieznanych parametrów a , b :

$$(1/2) (\partial U / \partial a) = 0 ; \quad (1/2) (\partial U / \partial b) = 0 .$$

Zadanie 10. Aproksymacja wielomianem

Informacja o zależności dwóch zmiennych x, y dana jest w postaci wyników $N=9$ niezależnych pomiarów obarczonych błędami przypadkowymi:

$$x = [0, 0.5, 1.0, 1.5, 2.0, 2.5, 3.0, 3.5, 4.0]$$

$$y = [1.02, 0.88, 0.48, 0.44, 0.33, 0.30, 0.15, 0.14, 0.12]$$

Dokonać aproksymacji funkcji, $y = f(x)$, wielomianem 3-go stopnia.

Idea rozwiązania

To zadanie rozwiązujemy metodą najmniejszych kwadratów (MNK). Wielomian stopnia trzeciego jest postaci:

$$y = f(x | a, b, c, d) = ax^3 + bx^2 + cx + d.$$

Początkowy układ 9 równań (liniowe względem a, b, c, d):

$$a \cdot 0^3 + b \cdot 0^2 + c \cdot 0 + d = 1.02 + \varepsilon_1$$

$$a \cdot 0.5^3 + b \cdot 0.5^2 + c \cdot 0.5 + d = 0.88 + \varepsilon_2$$

...

Zadanie 11. Model kNN w aproksymacji funkcji

Zastosować model pamięciowy uczenia się aproksymacji funkcji nad przestrzenią cech \mathbb{R}^2 . Zadanych jest 11 próbek uczących:

$\mathbf{c} = (x, y)$	(1;2,5)	(1; 3)	(1;3,5)	(2; 3)	(4; 3)	(2; 2)	(1; 1)	(2; 0)	(3; 1)	(3,5;1,5)	(4;1,5)
$f(\mathbf{c})$	1	1	1	2	2	3	3	3	3	4	4

Podać wartości aproksymowanej funkcji w metodzie 4 najbliższych sąsiadów dla cech (2; 2,5), (3, 3) i (1, 2).

Idea rozwiązania dla (2; 2.5).

Znajdujemy 4 najbliższych sąsiadów tego punktu -

$\mathbf{c} = (x, y)$	(1;2,5)	(1; 3)	(1;3,5)	(2; 3)	(4; 3)	(2; 2)	(1; 1)	(2; 0)	(3; 1)	(3,5;1,5)	(4;1,5)
$\ \mathbf{c} - (2; 2.5) \ $	1	$\sqrt{1.25}$	$\sqrt{2}$	0.5	$\sqrt{4.25}$	0.5	$\sqrt{3.25}$	2.5	$\sqrt{3.25}$	$\sqrt{3.25}$	$\sqrt{5}$

Rozwiązanie 11. Model kNN w aproksymacji

Idea rozwiązania dla (2; 2.5) (c.d.).

Najbliżsi 4 sąsiedzi to: (1, 2.5), (1, 3), (2, 3) i (2, 2):

$\mathbf{c} = (x, y)$	(1;2,5)	(1; 3)	(1;3,5)	(2; 3)	(4; 3)	(2; 2)	(1; 1)	(2; 0)	(3; 1)	(3,5;1,5)	(4;1,5)
$\ \mathbf{c} - (2; 2.5) \ $	1	$\sqrt{1.25}$	$\sqrt{2}$	0.5	$\sqrt{4.25}$	0.5	$\sqrt{3.25}$	2.5	$\sqrt{3.25}$	$\sqrt{3.25}$	$\sqrt{5}$

Stosujemy wzór na aproksymację funkcji w modelu kNN (średnia wartość dla k sąsiadów) otrzymując:

$$z = f(2,2.5) \approx \frac{1}{4}(1 + 1 + 2 + 3) = \frac{7}{4}$$

Zadanie 12. Model kNN w aproksymacji funkcji

Zilustrować zasadę modelu pamięciowego w uczeniu się aproksymacji funkcji, z zastosowaniem algorytmu k sąsiadów (kNN), dla $k = 3$. Niech pamięć zawiera przykłady uczące $U = \{x_1, x_2, \dots, x_{25}\}$, reprezentowane pojedynczą cechą c o postaci:

$$c_i = \varphi(x_i) = 0.006\pi \cdot i^{3/2}$$

Wartości przyjmowane dla tych przykładów przez funkcję docelową wynoszą: $f(c) = \frac{\sin c}{c}$

Obliczyć sumaryczny błąd i błąd średniokwadratowy dla aproksymacji funkcji reprezentowanej przez zapamiętane przykłady na zbiorze przykładów $T = (x_1', x_2', \dots, x_8')$, zadanych jako:

$$\varphi(x_i') = 0.05\pi \cdot i^{4/3}$$

Rozwiązanie 12 (1)

Idea rozwiązania

Należy napisać nieduży program, który posiada następujące kroki obliczeniowe:

1. Wyznacza 25 przykładów (próbek) uczących U :

i	1	2	3	4	24	25
c	0.006π	0.017π	0.031π	0.048π	0.705π	0.75π
$f(c)$	0.9999	0.9995	0.9984	0.9962	0.3610	0.3001

2. Próbkę tę są pamiętane i reprezentują komórki Voronoia w dziedzinie funkcji (w tym przypadku jest to 1-wymiarowa dziedzina i komórki mają postać przedziałów na osi c).

3. Wyznacza 8 przykładów w zbiorze testowym T :

i	1	2	3	4	5	6	7	8
c'	0.05π	0.126π	0.216π	0.317π	0.427π	0.545π	0.670π	0.800π
$f(c')$	

Rozwiązanie 12 (2)

Idea rozwiązania (c.d.)

4. Dla przykładów ze zbioru T ($c'_i \in T$) wyznacza aproksymację wartości funkcji $f'(c'_i)$ w oparciu o 3 najbliższych sąsiadów $\{c_k\}$:

$$f'(c'_i) = \frac{1}{3} \sum_{k=1}^3 f(c_k)$$

5. Każda z 8 aproksymowanych wartości jest porównywana z rzeczywistymi wartościami funkcji podanymi w zbiorze testowym:

$$\varepsilon_i = f(c'_i) - f'(c'_i), \text{ dla } i = 1, 2, \dots, 8$$

6. Sumaryczny błąd dla tych 8 aproksymowanych wartości: $E = \sum_{i=1}^8 \varepsilon_i$

7. Błąd średniokwadratowy: $E_2 = \frac{1}{8} \sum_{i=1}^8 \varepsilon_i^2$