



**MSI**

## **C6. Sieci neuronowe**

Włodzimierz Kasprzak

# Zadanie 1. Implementacja funkcji logicznych

Pojedynczy neuron może realizować liniowe funkcje logiczne. Przedstawić budowę pojedynczego neuronu implementującego funkcje logiczne (Boole'a):

- AND,
- OR,
- NOT.
- Przedstawić budowę sieci implementującej funkcję XOR.

# Rozwiązanie 1

Neuron realizuje funkcję iloczynu AND, gdy ustalimy dla niego wagi:


$w_0 = 1.5$ ,  $w_1 = 1$ ,  $w_2 = 1$ , a jako funkcję aktywacji wybierzemy funkcję skoku.

Neuron realizuje funkcję sumy OR, gdy ustalimy dla niego wagi:


$w_0 = 0.5$ ,  $w_1 = 1$ ,  $w_2 = 1$ , a jako funkcję aktywacji wybierzemy funkcję skoku.

Neuron realizuje funkcję negacji NOT, gdy ustalimy dla niego wagi:

$w_0 = -0.5$ ,  $w_1 = -1$ , a jako funkcję aktywacji wybierzemy funkcję skoku.



Sieć wielowarstwowa realizuje funkcję XOR.



# Zadanie 2. Uczenie sieci MLP

Wykonać jedną pełną iterację procesu uczenia 3-warstwowego **perceptronu (jedna warstwa ukryta)**, z 3 neuronami w warstwie ukrytej i po dwóch wejściach i wyjściach. Uczenie przebiega według podstawowej metody wstecznej propagacji błędów, przy następujących założeniach:

- stały współczynnik uczący  $= 0.1$ ,
- **sigmoidalna** funkcja aktywacji,  $z = \theta(y) = \frac{1}{1 + \exp(-y)}$
- początkowe wartości wag w macierzach  $\mathbf{W}^{(1)}$  i  $\mathbf{W}^{(2)}$  wynoszą

$$\mathbf{W}^{(1)} = \begin{bmatrix} 1 & -1 \\ 1 & 1 \\ -1 & 1 \end{bmatrix} \quad \mathbf{W}^{(2)} = \begin{bmatrix} 1 & -1 & 1 \\ -1 & 1 & -1 \end{bmatrix}$$

- pierwsza próbka ucząca:  $\mathbf{x}=(1,2)$ ;  $f(\mathbf{x}) = (1, 0)$ .

Dla ułatwienia można przybliżyć wartości funkcji aktywacji zgodnie z wartościami w poniższej tabelce:

y	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	1.0	1.1	2.0	3.0
z= $\theta(y)$	0.525	0.55	0.575	0.60	0.623	0.646	0.668	0.69	0.71	0.73	0.75	0.88	0.95

y	-3	-2	-1	-0.9	-0.8	-0.7	-0.6	-0.5	-0.4	-0.3	-0.2	-0.1	0.0
z= $\theta(y)$	0.05	0.12	0.27	0.29	0.31	0.33	0.35	0.375	0.40	0.425	0.45	0.475	0.50

## Rozwiązanie 2 (1)

1) Propagacja wprzód - z wejścia do wyjścia

$$\mathbf{y}^{(1)}(1) = \mathbf{W}^{(1)}(0) \cdot \mathbf{x}(1) = \begin{bmatrix} 1 & -1 \\ 1 & 1 \\ -1 & 1 \end{bmatrix} \cdot \begin{bmatrix} 1 \\ 2 \end{bmatrix} = \begin{bmatrix} -1 \\ 3 \\ 1 \end{bmatrix}$$

$$\mathbf{z}^{(1)}(1) = \psi(\mathbf{y}^{(1)}(1)) = \begin{bmatrix} 0.27 \\ 0.95 \\ 0.73 \end{bmatrix}$$

$$\mathbf{y}^{(2)}(1) = \mathbf{W}^{(2)}(0) \cdot \mathbf{z}^{(1)}(1) = \begin{bmatrix} 1 & -1 & 1 \\ -1 & 1 & -1 \end{bmatrix} \cdot \begin{bmatrix} 0.27 \\ 0.95 \\ 0.73 \end{bmatrix} = \begin{bmatrix} 0.05 \\ -0.05 \end{bmatrix}$$

$$\mathbf{z}^{(2)}(1) = \psi(\mathbf{y}^{(2)}(1)) = \begin{bmatrix} 0.5125 \\ 0.4875 \end{bmatrix}$$

## Rozwiązanie 2 (2)

2) Propagacja błędu wstecz

2.A) Wektor korekcji dla warstwy wyjściowej

$$\begin{aligned}\mathbf{d}^{(2)}(1) &= (\mathbf{s}(1) - \mathbf{z}^{(2)}(1)) .* (1 - \mathbf{z}^{(2)}(1)) .* \mathbf{z}^{(2)}(1) = \\ &= \left( \begin{bmatrix} 1 \\ 0 \end{bmatrix} - \begin{bmatrix} 0.5125 \\ 0.4875 \end{bmatrix} \right) .* \left( \begin{bmatrix} 1 \\ 1 \end{bmatrix} - \begin{bmatrix} 0.5125 \\ 0.4875 \end{bmatrix} \right) .* \begin{bmatrix} 0.5125 \\ 0.4875 \end{bmatrix} \cong \begin{bmatrix} 0.1218 \\ -0.1218 \end{bmatrix}\end{aligned}$$

2.B) Wektor korekcji dla warstwy ukrytej

$$\begin{aligned}\mathbf{d}^{(1)}(1) &= [\mathbf{W}^{(2)}(0)]^T \cdot \mathbf{d}^{(2)}(1) .* (1 - \mathbf{z}^{(1)}(1)) .* \mathbf{z}^{(1)}(1) = \\ &= \begin{bmatrix} 1.0 & -1.0 \\ -1.0 & 1.0 \\ 1.0 & -1.0 \end{bmatrix} \cdot \begin{bmatrix} 0.1218 \\ -0.1218 \end{bmatrix} .* \left( \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} - \begin{bmatrix} 0.27 \\ 0.95 \\ 0.73 \end{bmatrix} \right) .* \begin{bmatrix} 0.27 \\ 0.95 \\ 0.73 \end{bmatrix} = \\ &= \begin{bmatrix} 0.2436 \\ -0.2436 \\ 0.2436 \end{bmatrix} .* \begin{bmatrix} 0.1971 \\ 0.0475 \\ 0.1971 \end{bmatrix} \cong \begin{bmatrix} 0.04801 \\ -0.01157 \\ 0.04801 \end{bmatrix}\end{aligned}$$

## Rozwiązanie 2 (3)

3) Modyfikacja wag

3.A) Modyfikacja macierzy wag  $\mathbf{W}^{(2)}$

$$\Delta \mathbf{W}^{(2)}(1) = 0.1 \cdot \begin{bmatrix} 0.1218 \\ -0.1218 \end{bmatrix} \cdot \begin{bmatrix} 0.27 \\ 0.95 \\ 0.73 \end{bmatrix}^T = 0.1 \cdot \begin{bmatrix} 0.0329 & 0.1157 & 0.0889 \\ -0.0329 & -0.1157 & -0.0889 \end{bmatrix}$$

$$\mathbf{W}^{(2)}(1) = \mathbf{W}^{(2)}(0) + \Delta \mathbf{W}^{(2)}(1)$$

$$= \begin{bmatrix} 1 & -1 & 1 \\ -1 & 1 & -1 \end{bmatrix} + 0.1 \cdot \begin{bmatrix} 0.0329 & 0.1157 & 0.0889 \\ -0.0329 & -0.1157 & -0.0889 \end{bmatrix} =$$

$$\approx \begin{bmatrix} 1.0033 & -0.9884 & 1.0089 \\ -1.0033 & 0.9884 & -1.0089 \end{bmatrix}$$

## Rozwiązanie 2 (4)

3.B) Modyfikacja macierzy wag  $\mathbf{W}^{(1)}$

$$\Delta \mathbf{W}^{(1)}(1) = 0.1 \cdot \begin{bmatrix} 0.04801 \\ -0.01157 \\ 0.04801 \end{bmatrix} \cdot \begin{bmatrix} 1 \\ 2 \end{bmatrix}^T = 0.1 \cdot \begin{bmatrix} 0.04801 & 0.09602 \\ -0.01157 & -0.02314 \\ 0.04801 & 0.09602 \end{bmatrix}$$

Macierz wag  $\mathbf{W}^{(1)}$  po modyfikacji:

$$\mathbf{W}^{(1)}(1) = \mathbf{W}^{(1)}(0) + \Delta \mathbf{W}^{(1)}(1)$$

$$= \begin{bmatrix} 1 & -1 \\ 1 & 1 \\ -1 & 1 \end{bmatrix} + 0.1 \cdot \begin{bmatrix} 0.04801 & 0.09602 \\ -0.01157 & -0.02314 \\ 0.04801 & 0.09602 \end{bmatrix} \cong \begin{bmatrix} 1.00480 & -0.99040 \\ 0.99884 & 0.99769 \\ -0.99520 & 1.00960 \end{bmatrix}$$



# Zadanie 3. Entropia krzyżowa

Wykonać pierwszą iterację algorytmu uczenia sieci w pełni połączonej o jednej warstwie ukrytej, realizującej klasyfikację binarną – tzn. o **pojedynczym wyjściu, sigmoidalnej funkcji aktywacji i entropii krzyżowej** jako funkcji straty).

Założyć 3 neurony w warstwie ukrytej i dwa wejścia. Dalsze założenia:

Stała ucząca,  $\mu = 0.1$ ;

Sigmoidalna funkcja aktywacji:  $z = \theta(y) = \frac{1}{1 + \exp(-y)}$

Początkowa macierz wag  $\mathbf{W}^{(1)}$  i początkowy wektor wag  $\mathbf{w}^{(2)}$  :

$$\mathbf{W}^{(1)}(0) = \begin{bmatrix} 1 & -1 \\ 1 & 1 \\ -1 & 1 \end{bmatrix}; \quad \mathbf{w}^{(2)T}(0) = [1 \quad -1 \quad 1]$$

Pierwsza próbka danych,  $\mathbf{x}(1)=[1, 2]$ , należy do klasy dodatniej, tzn. oczekiwane wyjście,  $z(1)=f(\mathbf{x}(1))=1$ .

# Rozwiązanie 3 (1)

## 1. Propagacja wprzód

$$\mathbf{y}^{(1)}(1) = \mathbf{W}^{(1)}(0) \cdot \mathbf{x}(1) = \begin{bmatrix} 1 & -1 \\ 1 & 1 \\ -1 & 1 \end{bmatrix} \cdot \begin{bmatrix} 1 \\ 2 \end{bmatrix} = \begin{bmatrix} -1 \\ 3 \\ 1 \end{bmatrix}$$

$$\mathbf{z}^{(1)}(1) = \theta(\mathbf{y}^{(1)}(1)) = \begin{bmatrix} 0.27 \\ 0.95 \\ 0.73 \end{bmatrix}$$

$$y^{(2)}(1) = \mathbf{w}^{(2)T}(0) \cdot \mathbf{z}^{(1)}(1) = [1 \quad -1 \quad 1] \cdot \begin{bmatrix} 0.27 \\ 0.95 \\ 0.73 \end{bmatrix} = 0.05$$

$$z^{(2)}(1) = \theta(y^{(2)}(1)) \cong 0.5125$$

## 2. Wartość korekty dla wyjścia

$$d^{(2)}(1) = (s(1) - z^{(2)}(1)) = 1 - 0.5125 = 0.4875$$

## Rozwiązanie 3 (2)

3. Wektor korekty dla wag warstwy ukrytej

$$\begin{aligned}\mathbf{d}^{(1)}(1) &= \mathbf{w}^{(2)}(0) \cdot d^{(2)}(1) \cdot \left(1 - \mathbf{z}^{(1)}(1)\right) \cdot \mathbf{z}^{(1)}(1) = \\ &= \begin{bmatrix} 1 \\ -1 \\ 1 \end{bmatrix} \cdot 0.4875 \cdot \left(\begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} - \begin{bmatrix} 0.27 \\ 0.95 \\ 0.73 \end{bmatrix}\right) \cdot \begin{bmatrix} 0.27 \\ 0.95 \\ 0.73 \end{bmatrix} = \\ &= \begin{bmatrix} 0.4875 \\ -0.4875 \\ 0.4875 \end{bmatrix} \cdot \begin{bmatrix} 0.2241 \\ 0.0475 \\ 0.1971 \end{bmatrix} \cong \begin{bmatrix} 0.10925 \\ -0.02316 \\ 0.09609 \end{bmatrix}\end{aligned}$$

4. Modyfikacja wektora wag neuronu wyjściowego

$$\begin{aligned}\Delta \mathbf{w}^{(2)T}(1) &= \mu \cdot d^{(2)}(1) \cdot \mathbf{z}^{(1)T}(1) = 0.1 \cdot 0.4875 \cdot \begin{bmatrix} 0.27 \\ 0.95 \\ 0.73 \end{bmatrix}^T \\ &= 0.1 \cdot [0.1316 \quad 0.4631 \quad 0.3559] \\ \mathbf{w}^{(2)T}(1) &= \mathbf{w}^{(2)T}(0) + \Delta \mathbf{w}^{(2)T}(1) \\ &= [1 \quad -1 \quad 1] + 0.1 \cdot [0.1316 \quad 0.4631 \quad 0.3559] = \\ &\cong [1.0132 \quad -0.9537 \quad 1.0356]\end{aligned}$$

## Rozwiązanie 3 (3)

### 5. Modyfikacja macierzy wag warstwy ukrytej

$$\begin{aligned}\Delta \mathbf{W}^{(1)}(1) &= \mu \cdot \mathbf{d}^{(1)}(1) \cdot \mathbf{z}^{(0)T}(1) = \mu \cdot \mathbf{d}^{(1)}(1) \cdot \mathbf{x}(1) \\ &= 0.1 \cdot \begin{bmatrix} 0.10925 \\ -0.02316 \\ 0.09609 \end{bmatrix} \cdot \begin{bmatrix} 1 \\ 2 \end{bmatrix}^T = 0.1 \cdot \begin{bmatrix} 0.10925 & 0.21850 \\ -0.02316 & -0.04632 \\ 0.09609 & 0.19218 \end{bmatrix}\end{aligned}$$

$$\begin{aligned}\mathbf{W}^{(1)}(1) &= \mathbf{W}^{(1)}(0) + \Delta \mathbf{W}^{(1)}(1) = \begin{bmatrix} 1 & -1 \\ 1 & 1 \\ -1 & 1 \end{bmatrix} + 0.1 \cdot \begin{bmatrix} 0.10925 & 0.21850 \\ -0.02316 & -0.04632 \\ 0.09609 & 0.19218 \end{bmatrix} = \\ &\cong \begin{bmatrix} 1.0109 & -0.9782 \\ 0.9977 & 0.9954 \\ -0.9904 & 1.0192 \end{bmatrix}\end{aligned}$$

# Zadanie 4. Softmax

Wykonać pierwszą iterację algorytmu uczenia dwu-warstwowej sieci w pełni połączonej realizującej klasyfikację **wieloklasową** (przyjąć dwa wyjścia) z aktywacją typu **softmax** i **entropią krzyżową** jako funkcją straty.

Założyć 3 neurony w warstwie ukrytej i dwa wejścia. Dalsze założenia:

- Stała ucząca,  $\mu = 0.1$ ;
- Sigmoidalna funkcja aktywacji:  $z = \theta(y) = \frac{1}{1 + \exp(-y)}$
- Początkowe macierze wag  $\mathbf{W}^{(1)}$  i  $\mathbf{W}^{(2)}$  :

$$\mathbf{W}^{(1)}(0) = \begin{bmatrix} 1 & -1 \\ 1 & 1 \\ -1 & 1 \end{bmatrix}; \quad \mathbf{W}^{(2)}(0) = \begin{bmatrix} 1 & -1 & 1 \\ -1 & 1 & -1 \end{bmatrix}$$

- Pierwsza próbka danych,  $\mathbf{x}(1) = [1, 2]$  i oczekiwane wyjście,  $k(1) = f(\mathbf{x}(1)) = [1, 0]$ .

# Rozwiązanie 4 (1)

## 1. Propagacja wprzód

$$\mathbf{y}^{(1)}(1) = \mathbf{W}^{(1)}(0) \cdot \mathbf{x}(1) = \begin{bmatrix} 1 & -1 \\ 1 & 1 \\ -1 & 1 \end{bmatrix} \cdot \begin{bmatrix} 1 \\ 2 \end{bmatrix} = \begin{bmatrix} -1 \\ 3 \\ 1 \end{bmatrix}$$

$$\mathbf{z}^{(1)}(1) = \theta(\mathbf{y}^{(1)}(1)) = \begin{bmatrix} 0.27 \\ 0.95 \\ 0.73 \end{bmatrix}$$

$$\mathbf{y}^{(2)}(1) = \mathbf{W}^{(2)}(0) \cdot \mathbf{z}^{(1)}(1) = \begin{bmatrix} 1 & -1 & 1 \\ -1 & 1 & -1 \end{bmatrix} \cdot \begin{bmatrix} 0.27 \\ 0.95 \\ 0.73 \end{bmatrix} = \begin{bmatrix} 0.05 \\ -0.05 \end{bmatrix}$$

Aktywacja typu softmax w warstwie wyjściowej:

$$\mathbf{z} = \mathbf{y}, \quad \mathbf{z}^{(2)}(1) = \mathbf{y}^{(2)}(1) = \begin{bmatrix} 0.05 \\ -0.05 \end{bmatrix} = \begin{bmatrix} z_1 \\ z_2 \end{bmatrix}$$

$$s_i = \frac{\exp(z_i)}{\sum_{j=1}^2 \exp(z_j)}, \quad i = 1, 2$$

$$s_1 = \frac{\exp(0.05)}{\exp(0.05) + \exp(-0.05)} \cong \frac{1.05127}{1.05127 + 0.95123} = \frac{1.05127}{2.0025} \cong 0.525$$

$$s_2 = 1 - s_1 = 0.475 \quad \mathbf{s}^{(2)}(1) \cong \begin{bmatrix} 0.525 \\ 0.475 \end{bmatrix}$$

## Rozwiązanie 4 (2)

2. Wektor korekty dla neuronów warstwy wyjściowej

$$\mathbf{d}^{(2)}(1) = \mathbf{k}(1) - \mathbf{s}^{(2)}(1) = \left( \begin{bmatrix} 1 \\ 0 \end{bmatrix} - \begin{bmatrix} 0.525 \\ 0.475 \end{bmatrix} \right) = \begin{bmatrix} 0.475 \\ -0.475 \end{bmatrix}$$

3. Wektor korekty dla neuronów warstwy ukrytej

$$\begin{aligned} \mathbf{d}^{(1)}(1) &= [\mathbf{W}^{(2)}(0)]^T \cdot \mathbf{d}^{(2)}(1) \cdot (1 - \mathbf{z}^{(1)}(1)) \cdot \mathbf{z}^{(1)}(1) = \\ &= \begin{bmatrix} 1 & -1 \\ -1 & 1 \\ 1 & -1 \end{bmatrix} \cdot \begin{bmatrix} 0.475 \\ -0.475 \end{bmatrix} \cdot \left( \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} - \begin{bmatrix} 0.27 \\ 0.95 \\ 0.73 \end{bmatrix} \right) \cdot \begin{bmatrix} 0.27 \\ 0.95 \\ 0.73 \end{bmatrix} = \\ &= \begin{bmatrix} 0.95 \\ -0.95 \\ 0.95 \end{bmatrix} \cdot \begin{bmatrix} 0.2241 \\ 0.0475 \\ 0.1971 \end{bmatrix} \cong \begin{bmatrix} 0.2128 \\ -0.04513 \\ 0.1872 \end{bmatrix} \end{aligned}$$

4. Modyfikacja wag warstwy wyjściowej

$$\begin{aligned} \Delta \mathbf{W}^{(2)}(1) &= \mu \cdot \mathbf{d}^{(2)}(1) \cdot \mathbf{z}^{(1)T}(1) = 0.1 \cdot \begin{bmatrix} 0.475 \\ -0.475 \end{bmatrix} \cdot \begin{bmatrix} 0.27 \\ 0.95 \\ 0.73 \end{bmatrix}^T \\ &= 0.1 \cdot \begin{bmatrix} 0.12825 & 0.45125 & 0.34675 \\ -0.12825 & -0.45125 & -0.34675 \end{bmatrix} \end{aligned}$$



## Rozwiązanie 4 (3)

$$\begin{aligned}\mathbf{W}^{(2)}(1) &= \mathbf{W}^{(2)}(0) + \Delta \mathbf{W}^{(2)}(1) \\ &= \begin{bmatrix} 1 & -1 & 1 \\ -1 & 1 & -1 \end{bmatrix} + 0.1 \cdot \begin{bmatrix} 0.12825 & 0.45125 & 0.34675 \\ -0.12825 & -0.45125 & -0.34675 \end{bmatrix} = \\ &\cong \begin{bmatrix} 1.0128 & -0.9549 & 1.0347 \\ -1.0128 & 0.9549 & -1.0347 \end{bmatrix}\end{aligned}$$

5. Modyfikacja macierzy wag warstwy ukrytej

$$\begin{aligned}\Delta \mathbf{W}^{(1)}(1) &= \mu \cdot \mathbf{d}^{(1)}(1) \cdot \mathbf{z}^{(0)T}(1) = \mu \cdot \mathbf{d}^{(1)}(1) \cdot \mathbf{x}(1) \\ &= 0.1 \cdot \begin{bmatrix} 0.2128 \\ -0.04513 \\ 0.1872 \end{bmatrix} \cdot \begin{bmatrix} 1 \\ 2 \end{bmatrix}^T = 0.1 \cdot \begin{bmatrix} 0.2128 & 0.4256 \\ -0.04513 & -0.09026 \\ 0.1872 & 0.3744 \end{bmatrix}\end{aligned}$$

$$\begin{aligned}\mathbf{W}^{(1)}(1) &= \mathbf{W}^{(1)}(0) + \Delta \mathbf{W}^{(1)}(1) = \begin{bmatrix} 1 & -1 \\ 1 & 1 \\ -1 & 1 \end{bmatrix} + 0.1 \cdot \begin{bmatrix} 0.2128 & 0.4256 \\ -0.04513 & -0.09026 \\ 0.1872 & 0.3744 \end{bmatrix} = \\ &\cong \begin{bmatrix} 1.0213 & -0.9574 \\ 0.9955 & 0.9910 \\ -0.9813 & 1.0374 \end{bmatrix}\end{aligned}$$



# Zadanie 5. RNN

Wykonać dwie iteracje algorytmu uczenia **sieci rekurencyjnej** z jedną warstwą ukrytą, realizującą klasyfikację **wieloklasową**. Przyjąć dwa wyjścia z aktywacją typu **softmax** i **entropią krzyżową** jako funkcją straty.

Założyć 3 neurony w warstwie ukrytej i dwa wejścia. Dalsze założenia:

Stała ucząca,  $\mu = 0.1$ ;

Sigmoidalna funkcja aktywacji w warstwie ukrytej:  $z = \theta(y) = \frac{1}{1 + \exp(-y)}$

Początkowe wagi sieci:


$$\mathbf{V}_h(0) = \begin{bmatrix} 1 & -1 \\ 1 & 1 \\ -1 & 1 \end{bmatrix}; \quad \mathbf{W}_y(0) = \begin{bmatrix} 1 & -1 & 1 \\ -1 & 1 & -1 \end{bmatrix}; \quad \mathbf{U}_h(0) = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 1 & 0 & 1 \end{bmatrix};$$

Pierwsze dwie próbki uczące:  $\mathbf{x}(1) = [1, 2]^T$ ;  $\mathbf{x}(2) = [2, 1]^T$ ;

Etykiety wyjść:  $\mathbf{k}(1) = [1, 0]^T$ ;  $\mathbf{k}(2) = [0, 1]^T$

# Zadanie 5 (c.d.)

Sieć RNN z jedną warstwą ukrytą:



# Rozwiązanie 5 (1)

## Iteracja 1.

### 1.1 Propagacja wprzód

$$\mathbf{h}(1) = \mathbf{V}_h(0) \cdot \mathbf{x}(1) + \mathbf{U}_h(0) \cdot \mathbf{h}(0) = \begin{bmatrix} 1 & -1 \\ 1 & 1 \\ -1 & 1 \end{bmatrix} \cdot \begin{bmatrix} 1 \\ 2 \end{bmatrix} + \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 1 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} -1 \\ 3 \\ 1 \end{bmatrix}$$

$$\mathbf{z}^{(1)}(1) = \theta(\mathbf{h}(1)) = \begin{bmatrix} 0.27 \\ 0.95 \\ 0.73 \end{bmatrix}$$

$$\mathbf{y}(1) = \mathbf{W}_y(0) \cdot \mathbf{z}^{(1)}(1) = \begin{bmatrix} 1 & -1 & 1 \\ -1 & 1 & -1 \end{bmatrix} \cdot \begin{bmatrix} 0.27 \\ 0.95 \\ 0.73 \end{bmatrix} = \begin{bmatrix} 0.05 \\ -0.05 \end{bmatrix}$$

$$\mathbf{z}(1) = \mathbf{y}(1) = \begin{bmatrix} 0.05 \\ -0.05 \end{bmatrix} = \begin{bmatrix} z_1 \\ z_2 \end{bmatrix}$$

$$s_i = \frac{\exp(z_i)}{\sum_{j=1}^2 \exp(z_j)}, \quad i = 1, 2$$

$$s_1 = \frac{\exp(0.05)}{\exp(0.05) + \exp(-0.05)} \cong \frac{1.05127}{1.05127 + 0.95123} = \frac{1.05127}{2.0025} \cong 0.525$$

# Rozwiązanie 5 (2)

Iteracja 1) 1.1 Propagacja wprzód (c.d.)

$$s_1 \cong 0.525$$

$$s_2 = 1 - s_1 = 0.475$$

Wyjście po iteracji 1:  $\mathbf{s}^{(2)}(1) \cong \begin{bmatrix} 0.525 \\ 0.475 \end{bmatrix}$

1.2 Propagacja błędu wstecz

Korekta dla wyjścia:  $\mathbf{d}^{(2)}(1) = \mathbf{k}(1) - \mathbf{s}^{(2)}(1) = \left( \begin{bmatrix} 1 \\ 0 \end{bmatrix} - \begin{bmatrix} 0.525 \\ 0.475 \end{bmatrix} \right) = \begin{bmatrix} 0.475 \\ -0.475 \end{bmatrix}$

Korekta dla warstwy ukrytej:  $\mathbf{d}^{(1)}(1) = [\mathbf{W}_y(0)]^T \cdot \mathbf{d}^{(2)}(1) \cdot * (1 - \mathbf{z}^{(1)}(1)) \cdot * \mathbf{z}^{(1)}(1) =$   
$$= \begin{bmatrix} 1 & -1 \\ -1 & 1 \\ 1 & -1 \end{bmatrix} \cdot \begin{bmatrix} 0.475 \\ -0.475 \end{bmatrix} \cdot * \left( \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} - \begin{bmatrix} 0.27 \\ 0.95 \\ 0.73 \end{bmatrix} \right) \cdot * \begin{bmatrix} 0.27 \\ 0.95 \\ 0.73 \end{bmatrix} =$$
  
$$= \begin{bmatrix} 0.95 \\ -0.95 \\ 0.95 \end{bmatrix} \cdot * \begin{bmatrix} 0.2241 \\ 0.0475 \\ 0.1971 \end{bmatrix} \cong \begin{bmatrix} 0.2128 \\ -0.04513 \\ 0.1872 \end{bmatrix}$$

# Rozwiązanie 5 (3)

Iteracja 1) 1.3 Modyfikacja wag

$$\begin{aligned}\Delta \mathbf{W}^{(2)}(1) &= \mu \cdot \mathbf{d}^{(2)}(1) \cdot \mathbf{z}^{(1)T}(1) = 0.1 \cdot \begin{bmatrix} 0.475 \\ -0.475 \end{bmatrix} \cdot \begin{bmatrix} 0.27 \\ 0.95 \\ 0.73 \end{bmatrix}^T \\ &= 0.1 \cdot \begin{bmatrix} 0.12825 & 0.45125 & 0.34675 \\ -0.12825 & -0.45125 & -0.34675 \end{bmatrix}\end{aligned}$$

$$\begin{aligned}\mathbf{W}^{(2)}(1) &= \mathbf{W}^{(2)}(0) + \Delta \mathbf{W}^{(2)}(1) \\ &= \begin{bmatrix} 1 & -1 & 1 \\ -1 & 1 & -1 \end{bmatrix} + 0.1 \cdot \begin{bmatrix} 0.12825 & 0.45125 & 0.34675 \\ -0.12825 & -0.45125 & -0.34675 \end{bmatrix} = \\ &\cong \begin{bmatrix} 1.0128 & -0.9549 & 1.0347 \\ -1.0128 & 0.9549 & -1.0347 \end{bmatrix}\end{aligned}$$

$$\begin{aligned}\Delta \mathbf{V}_h(1) &= \mu \cdot 0.5 \cdot \mathbf{d}^{(1)}(1) \cdot \mathbf{x}(1)^T = 0.05 \cdot \begin{bmatrix} 0.2128 \\ -0.04513 \\ 0.1872 \end{bmatrix} \cdot \begin{bmatrix} 1 \\ 2 \end{bmatrix}^T \\ &= 0.05 \cdot \begin{bmatrix} 0.2128 & 0.4256 \\ -0.04513 & -0.09026 \\ 0.1872 & 0.3744 \end{bmatrix}\end{aligned}$$

## Rozwiązanie 5 (4)

Iteracja 1) 1.3 Modyfikacja wag (c.d.)

$$\begin{aligned} \mathbf{V}_h(1) &= \mathbf{V}_h(0) + \Delta \mathbf{V}_h(1) = \begin{bmatrix} 1 & -1 \\ 1 & 1 \\ -1 & 1 \end{bmatrix} + 0.1 \cdot \begin{bmatrix} 0.1064 & 0.2128 \\ -0.02256 & -0.04513 \\ 0.0936 & 0.1872 \end{bmatrix} = \\ &\cong \begin{bmatrix} 1.0106 & -0.9787 \\ 0.9977 & 0.9955 \\ -0.9904 & 1.0187 \end{bmatrix} \end{aligned}$$

$$\begin{aligned} \Delta \mathbf{U}_h(1) &= \mu \cdot 0.5 \cdot \mathbf{d}^{(1)}(1) \cdot \mathbf{h}(0)^T = 0.05 \cdot \begin{bmatrix} 0.2128 \\ -0.04513 \\ 0.1872 \end{bmatrix} \cdot \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}^T = 0.05 \cdot \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \\ \mathbf{U}_h(1) &= \mathbf{U}_h(0) + \Delta \mathbf{U}_h(1) = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 1 & 0 & 1 \end{bmatrix} \end{aligned}$$

# Rozwiązanie 5 (5)

## Iteracja 2. 2.1 Propagacja wprzód

$$\mathbf{h}(2) = \mathbf{V}_h(1) \cdot \mathbf{x}(2) + \mathbf{U}_h(1) \cdot \mathbf{h}(1) = \begin{bmatrix} 1.0106 & -0.9787 \\ 0.9977 & 0.9955 \\ -0.9904 & 1.0187 \end{bmatrix} \cdot \begin{bmatrix} 2 \\ 1 \end{bmatrix} + \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 1 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} -1 \\ 3 \\ 1 \end{bmatrix}$$
$$= \begin{bmatrix} 1.0425 \\ 6.9909 \\ -0.9621 \end{bmatrix}$$

$$\mathbf{z}^{(1)}(2) = \theta(\mathbf{h}(2)) = \begin{bmatrix} 0.7393 \\ 0.9991 \\ 0.2765 \end{bmatrix}$$

$$\mathbf{y}(2) = \mathbf{W}_y(1) \cdot \mathbf{z}^{(1)}(2) = \begin{bmatrix} 1.0128 & -0.9549 & 1.0347 \\ -1.0128 & 0.9549 & -1.0347 \end{bmatrix} \cdot \begin{bmatrix} 0.7393 \\ 0.9991 \\ 0.2765 \end{bmatrix} = \begin{bmatrix} 0.0808 \\ -0.0808 \end{bmatrix}$$

$$\mathbf{z}(1) = \mathbf{y}(1) = \begin{bmatrix} 0.0808 \\ -0.0808 \end{bmatrix} = \begin{bmatrix} z_1 \\ z_2 \end{bmatrix}$$

$$s_i = \frac{\exp(z_i)}{\sum_{j=1}^2 \exp(z_j)}, \quad i = 1, 2$$

$$s_1 = \frac{\exp(0.0808)}{\exp(0.0808) + \exp(-0.0808)} \cong \frac{1.0842}{1.0842 + 0.9224} = \frac{1.0842}{2.0065} \cong 0.5403$$

# Rozwiązanie 5 (6)

Iteracja 2) 2.1 Propagacja wprzód (c.d.)

$$s_1 \cong 0.540$$

$$s_2 = 1 - s_1 = 0.460$$

Wyjście po iteracji 2:  $\mathbf{s}^{(2)}(2) \cong \begin{bmatrix} 0.540 \\ 0.460 \end{bmatrix}$

2.2 Propagacja błędu wstecz

Korekta dla wyjścia:  $\mathbf{d}^{(2)}(2) = \mathbf{k}(2) - \mathbf{s}^{(2)}(2) = \left( \begin{bmatrix} 0 \\ 1 \end{bmatrix} - \begin{bmatrix} 0.540 \\ 0.460 \end{bmatrix} \right) = \begin{bmatrix} -0.54 \\ 0.54 \end{bmatrix}$

Korekta dla warstwy ukrytej:

$$\begin{aligned} \mathbf{d}^{(1)}(2) &= [\mathbf{W}_y(1)]^T \cdot \mathbf{d}^{(2)}(2) .* (1 - \mathbf{z}^{(1)}(2)) .* \mathbf{z}^{(1)}(2) = \\ &= \begin{bmatrix} 1.0128 & -1.0128 \\ -0.9549 & 0.9549 \\ 1.0347 & -1.0347 \end{bmatrix} \cdot \begin{bmatrix} -0.54 \\ 0.54 \end{bmatrix} .* \left( \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} - \begin{bmatrix} 0.7393 \\ 0.9991 \\ 0.2765 \end{bmatrix} \right) .* \begin{bmatrix} 0.7393 \\ 0.9991 \\ 0.2765 \end{bmatrix} = \\ &\cong \begin{bmatrix} -0.2108 \\ 0.0009 \\ -0.2235 \end{bmatrix} \end{aligned}$$



# Rozwiązanie 5 (7)

Iteracja 2) 2.3 Modyfikacja wag

$$\Delta \mathbf{W}^{(2)}(2) = \mu \cdot \mathbf{d}^{(2)}(2) \cdot \mathbf{z}^{(1)T}(2)$$

$$\mathbf{W}^{(2)}(2) = \mathbf{W}^{(2)}(1) + \Delta \mathbf{W}^{(2)}(2)$$

$$\Delta \mathbf{V}_h(2) = \mu \cdot 0.5 \cdot \mathbf{d}^{(1)}(2) \cdot \mathbf{x}(2)^T$$

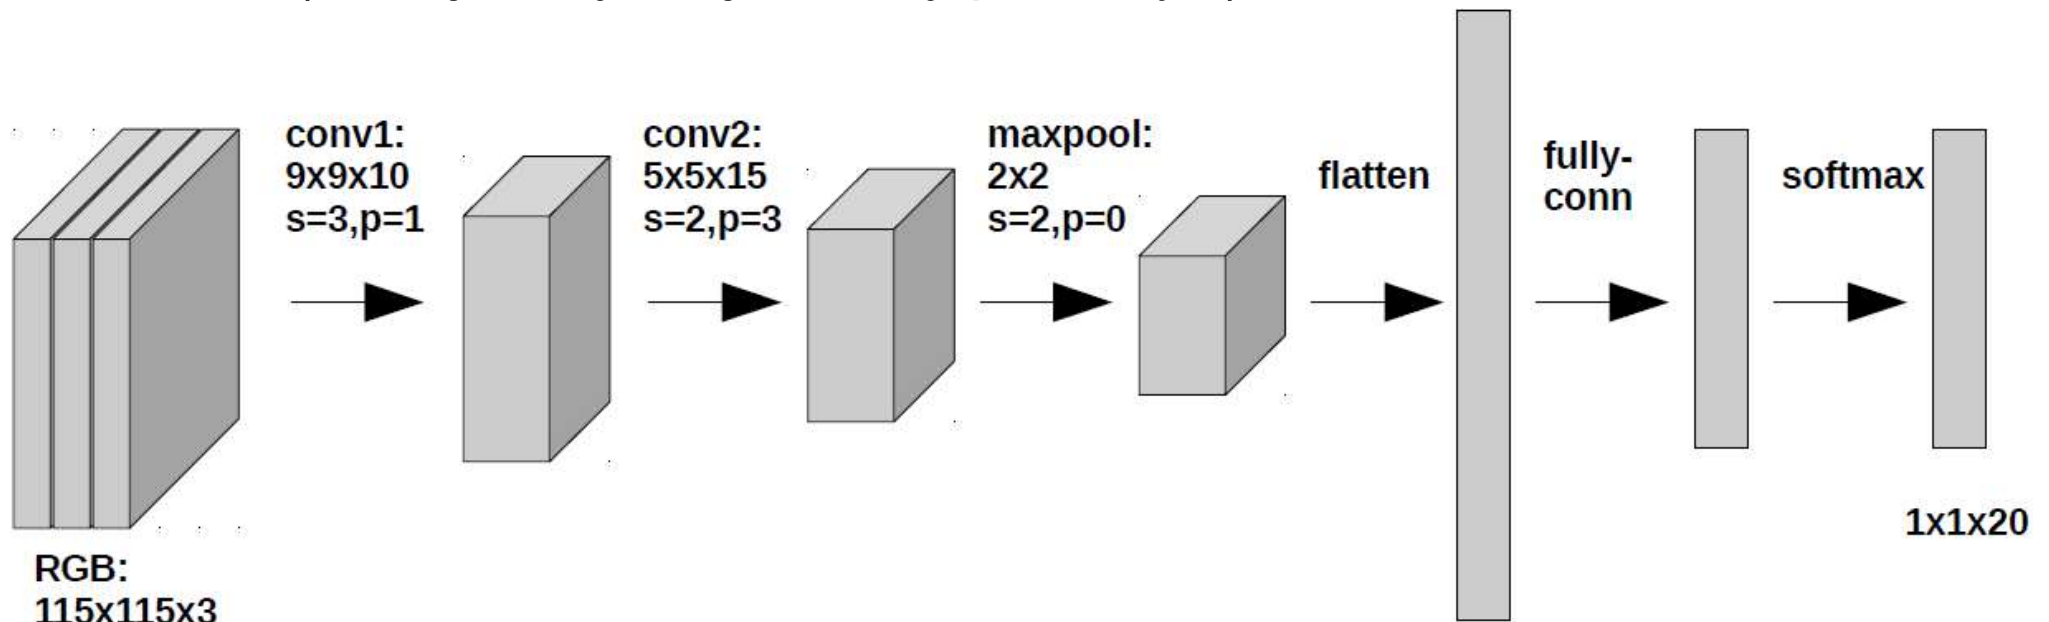
$$\mathbf{V}_h(2) = \mathbf{V}_h(1) + \Delta \mathbf{V}_h(2)$$

$$\Delta \mathbf{U}_h(2) = \mu \cdot 0.5 \cdot \mathbf{d}^{(1)}(2) \cdot \mathbf{h}(1)^T$$

$$\mathbf{U}_h(2) = \mathbf{U}_h(1) + \Delta \mathbf{U}_h(2)$$

# Zadanie 6. Analiza sieci CNN

Dany jest model Splotowej Sieci Neuronowej (CNN) o następującej strukturze (funkcje aktywacji zostały pominięte):



Parametry splotu są podane jako  $filterH \times filterW \times numFilter$ ; warstwy max-pooling są określone jako  $filterH \times filterW$ ;  $s$  jest parametrem *stride*, a  $p$  jest parametrem *symmetrical padding*.

Warstwa *flatten* przekształca (zachowując liczbę elementów) wolumen danych do wektora. Początkowy i końcowy rozmiar wolumenów został podany na rysunku.

# Zadanie 6 (c.d.)

## Zadania

- Obliczyć rozmiary wolumenów danych dla każdej warstwy sieci
- Obliczyć liczby wag dla każdej warstwy sieci (włączając wagę wartości stałej 'bias').
- Obliczyć całkowitą liczbę wag sieci.

# Rozwiązanie 6 (1)

## Warstwa spłotowa

- Volumen wejściowy:  $V_{in} = H_{in} \times W_{in} \times C_{num}$   
(wysokość obrazu  $\times$  szerokość obrazu  $\times$  liczba kanałów – składowe koloru)
- „Stride”:  $(S_h, S_w)$  - jądro filtru przesuwa się po obrazie o  $(S_h, S_w)$  zamiast  $(1, 1)$ ;
- „Padding”:  $(P_h, P_w)$  - poszerzenie obrazu (kanału) wejściowego o  $(P_h, P_w)$  w celu pełnego wykorzystania brzegowych danych;
- Liczba filtrów :  $f_{num}$ , rozmiar filtrów  $f_w \times f_h \times C_{num}$

**Volumen wyjściowy warstwy**,  $H_{out} \times W_{out} \times f_{num}$ , wyznaczony jest jako:


$$H_{out} = \frac{H_{in} - f_h + 2P_h}{S_h} + 1$$
$$W_{out} = \frac{W_{in} - f_w + 2P_w}{S_w} + 1$$

a liczba kanałów na wyjściu wynosi  $f_{num}$ .

**Liczba wag warstwy**,  $L_{weights} = (f_h \times f_w \times C_{num} + 1) \times f_{num}$

# Rozwiązanie 6 (2)

## Warstwa spłotowa nr 1 (conv1)



- Volumen wejściowy:  $V_{in} = H_{in} \times W_{in} \times C_{num} = 115 \cdot 115 \cdot 3 = 39.675$
- „Stride”:  $(S_h, S_w) = (3, 3)$
- „Padding”:  $(P_h, P_w) = (1, 1)$
- Liczba filtrów :  $f_{num}=10$ , rozmiar filtrów  $f_w \times f_h \times C_{num}=9 \times 9 \times 3$


Volumen wyjściowy warstwy,  $V_{out}(conv1) = H_{out} \times W_{out} \times f_{num} = 37 \cdot 37 \cdot 10 = 13.690$ , gdzie :

$$H_{out} = \frac{115 - 9 + 2 \cdot 1}{3} + 1 = 37 ; \quad W_{out} = \frac{115 - 9 + 2 \cdot 1}{3} + 1 = 37$$

Liczba wag warstwy,  $L_{weights}(conv1) = (f_h \times f_w \times C_{num} + 1) \times f_{num} = (9 \cdot 9 \cdot 3 + 1) \cdot 10 = 2.440$

# Rozwiązanie 6 (3)

## Warstwa spłotowa nr 2 (conv2)



- Volumen wejściowy:  $V_{in} = H_{in} \times W_{in} \times f_{num} = 37 \cdot 37 \cdot 10 = 13.690$
- „Stride”:  $(S_h, S_w) = (2, 2)$
- „Padding”:  $(P_h, P_w) = (3, 3)$
- Liczba filtrów :  $f_{num}=15$ , rozmiar filtrów  $f_w \times f_h \times C_{num} = 5 \times 5 \times 10$

Volumen wyjściowy warstwy,  $V_{out}(conv2) = H_{out} \times W_{out} \times f_{num} = 20 \cdot 20 \cdot 15 = 6.000$ , gdzie :

$$H_{out} = \frac{37 - 5 + 2 \cdot 3}{2} + 1 = 20 ; \quad W_{out} = \frac{37 - 5 + 2 \cdot 3}{2} + 1 = 20$$


Liczba wag warstwy,  $L_{weights}(conv1) = (f_h \times f_w \times C_{num} + 1) \times f_{num} = (5 \cdot 5 \cdot 10 + 1) \cdot 15 = 3.765$

# Rozwiązanie 6 (4)

## Warstwa „pooling” (pod-próbkowanie)

- Zadaniem warstwy „pooling” jest ograniczenie rozmiaru danych. Stosowana jest filtracja lokalna realizująca ustalone funkcje (brak wag/parametrów do trenowania). Typowe funkcje to MAX (wybiera maksymalną wartość) lub AVERAGE (wyznacza średnią wartość).
- Filtracja wykonywana jest osobno dla każdego kanału.

## Warstwa „maxpool”



- Volumen wejściowy:  $V_{in} = H_{in} \times W_{in} \times C_{num} = 20 \cdot 20 \cdot 15 = 6.000$
- „Stride”:  $(S_h, S_w) = (2, 2)$
- „Padding”:  $(P_h, P_w) = (0, 0)$
- Liczba filtrów :  $f_{num}=15$ , rozmiar filtrów  $f_w \times f_h = 2 \times 2$

# Rozwiązanie 6 (5)

## Warstwa „maxpool” (c.d.)

Volumen wyjściowy warstwy,  $V_{out} = H_{out} \times W_{out} \times f_{num} = 10 \cdot 10 \cdot 15 = 1.500$ , gdzie  $H_{out}, W_{out}$  wyznaczone są identycznie jak dla warstwy spłotowej jako:

$$H_{out} = \frac{H_{in} - f_h + 2P_h}{S_h} + 1 = \frac{20 - 2 + 2 \cdot 0}{2} + 1 = 10$$
$$W_{out} = \frac{W_{in} - f_w + 2P_w}{S_w} + 1 = \frac{20 - 2 + 2 \cdot 0}{2} + 1 = 10$$

Liczba wag warstwy,  $L_{weights}(maxpool) = 0$

## Funkcja „flatten” (skanowanie)


Przekształcenie volumenu wejściowego,

$V_{in} = H_{in} \times W_{in} \times C_{num}$ , na wektor 1-wymiarowy,

$V_{out} = 1 \times 1 \times H_{in} \cdot W_{in} \cdot C_{num}$ .

W tym zadaniu:  $V_{out} = 1 \times 1 \times 10 \cdot 10 \cdot 15 = 1.500$

Liczba wag warstwy,  $L_{weights}(flatten) = 0$





# Rozwiązanie 6 (6)

## Warstwa „w pełni połączona” (FC)

Wektor wejściowy:  $V_{in}(FC) = 1 \times 1 \times 1.500$ .

Wektor wyjściowy warstwy FC odpowiada wyjściu funkcji „softmax”:  $V_{out}(FC) = 1 \times 1 \times 20 = 20$ .

Liczba wag warstwy,  $L_{weights}(FC) = 20 \cdot (1.500 + 1) = 30.020$

## Funkcja „softmax”


Wektor wejściowy:  $V_{in}(softmax) = 1 \times 1 \times 20$

Wektor wyjściowy:  $V_{out}(softmax) = 1 \times 1 \times 20$

Liczba wag warstwy,  $L_{weights}(softmax) = 0$

## Całkowita liczba wag tej sieci:

$2.440 + 3.765 + 0 + 0 + 30.020 + 0 = 36.225$



# Zadanie 7. Sieć dla problemu kWTA

Napisać program symulujący działanie sieci rekurencyjnej rozwiązującej problem znalezienia  $k$  zwycięzców (kWTA) ze zbioru  $N$  dodatnich liczb.

# Rozwiązanie 7 (1)

Program w Matlabie:

```
function [z, iternum] = kWTA( u, maxiter, k )  
% Argumenty: u - wektor „n” liczb (sygnały wejściowe dla sieci),  
%           maxiter – maksymalna liczba iteracji,  
%           k – liczba szukanych zwycięzców.  
% Zwracany wynik: z – wektor „n” liczb (sygnały wyjściowe) –  
% niezerowa wartość na i-tym wyjściu wskazuje, że odpowiednie  
% i-te wejście należy do zbioru „k zwycięzców”.  
    [c, n] = size(u);  
    if (k > (n-1)) % błędna wartość argumentu k  
        iternum = 0;  
        z = u;  
        return;  
    end  
    eps = 1.0/(n+k);
```

# Rozwiązanie 7 (2)

```
% Inicjalizacja
z = u; newz = z;
iternum = maxiter; % maksymalna liczba iteracji
for i=1 : maxiter % ewentualnie przerwij wcześniej, jeśli problem zostanie
rozwiązany
    sumuvec = sum(z);    zeronum = 0;
    for j=1:n
        newz(j) = u(j) + z(j) - eps *(sumuvec - z(j)); % reguła modyfikacji sieci RNN
        if newz(j) < 0 % nieliniowość RELU
            newz(j) = 0;    zeronum = zeronum +1;
        end
    end
    z = newz; % synchroniczna modyfikacja wszystkich wyjść
    % Sprawdź aktualną liczbę niezerowych wyjść u(j):
    if zeronum >= (n-k)
        iternum = i;    break; // zakończ
    end
end
```